



Universidade Federal do Pará
Faculdade de Ciência e Tecnologia

Antenor Aires da Silva Neto

**Desenvolvimento de um Sistema de Gerenciamento de Energia para
Edifícios Inteligentes**

BELÉM-PA

2023

Antenor Aires da Silva Neto

**Desenvolvimento de um Sistema de Gerenciamento de Energia para
Edifícios Inteligentes**

Trabalho de Conclusão de Curso apresentado no
Curso de Bacharelado interdisciplinar em Ciência e
Tecnologia da Universidade Federal do Pará -
UFPA, para obtenção do título de bacharel Ciência
e Tecnologia.

Orientador: Prof. Dr. Claudio Fialho

BELÉM-PA

2023

Resumo

Abstract

LISTA DE FIGURAS

<i>Figura 1: Representação de integrações do IoT</i>	14
<i>Figura 2: A casa inteligente</i>	17
<i>Figura 3: Número de casas inteligentes Europa x América do Norte</i>	18
<i>Figura 4: Sede da Environmental Systems Inc.</i>	20
<i>Figura 5: Torres Al-Bahr</i>	21
<i>Figura 6: Edifício Eldorado Business Tower</i>	22
<i>Figura 7: EPMS</i>	27
<i>Figura 8: Procedimentos a seguir no processo de determinação dos IEE</i>	33
<i>Figura 9: Consumos no IEES e IEET</i>	35
<i>Figura 10: Mínimos quadrados</i>	38
<i>Figura 11: Exemplo classificador árvore de decisão</i>	39
<i>Figura 12: Modelo Random Forest</i>	40
<i>Figura 13: Representação de um Neurônio Artificial</i>	42
<i>Figura 14: Funções de ativação Limiar (Threshold) e Sigmóide</i>	43
<i>Figura 15 : Importando as bibliotecas e os dados para o Google Colab</i>	49
<i>Figura 16: Transformação dos dados</i>	50
<i>Figura 17: Consumo energético por mês</i>	51
<i>Figura 18: Consumo por Categoria em kW</i>	52
<i>Figura 19: Gráfico de correlação</i>	54
<i>Figura 20: Regressão Linear</i>	55
<i>Figura 21: Árvore do modelo</i>	56
<i>Figura 22: Predição Árvore de decisão</i>	57
<i>Figura 23: Predição Random Forest</i>	59
<i>Figura 24: Features Importantes</i>	60
<i>Figura 25: Predição XGBoost</i>	61
<i>Figura 26: Predição RNA</i>	63

LISTA TABELAS

<i>Tabela 1: Passos Random Forest.....</i>	<i>40</i>
<i>Tabela 2: Avaliação da regressão linear</i>	<i>55</i>
<i>Tabela 3: Avaliação da Arvore de decisão.....</i>	<i>58</i>
<i>Tabela 4: Avaliação Random Forest.....</i>	<i>59</i>
<i>Tabela 5: Avaliação XGBoost</i>	<i>62</i>
<i>Tabela 6: Avaliação RNA.....</i>	<i>63</i>

Siglas

SUMÁRIO

1	INTRODUÇÃO	10
2	OBJETIVOS	11
2.1	OBJETIVOS ESPECIFICOS	11
3	METODOLOGIA	12
4	REFERENCIAS BIBLIOGRAFICAS	13
4.1	INTERNET DAS COISAS (IoT)	13
4.2	SMART HOMES	15
4.3	EDIFICIOS INTELIGENTES (EI)	18
4.3.1	EIs PELO MUNDO	19
4.3.2	CARECTERISTICAS DOS EI	22
4.3.3	AUTOMAÇÃO RESIDENCIAL	23
4.3.3.1	HVAC	23
4.3.3.2	CONTROLE DE ILUMINAÇÃO	25
4.3.3.3	CONTROLE DE ENERGIA ELETRICA	26
4.3.3.4	GERENCIAMENTO DO EDIFICIO	27
4.3.3.5	EFICIÊNCIA ENERGÉTICA	28
4.4	GERENCIAMENTO DE ENERGIA	29
4.4.1	ISO 50001	30
4.4.2	INDICADORES DE EFICIÊNCIA ENERGÉTICA (IEE)	31
4.4.3	GESTÃO ENERGÉTICA E INDICADORES PARA EDIFICIOS.	33
4.5	ALGORITMOS DE MACHINE LEARNING	35
4.5.1	REGRESSÃO LINEAR	37
4.5.2	ARVORE DE DECISÃO	38
4.5.3	RANDOM FOREST	40
4.5.4	Extreme Gradient Boosting (XGboost)	41
4.5.5	REDES NEURAIAS ARTIFICIAIS (RNAs)	42
4.5.6	AVALIAÇÃO DAS PREDIÇÕES	43
5	RESULTADOS E DISCUSSÃO	46
5.1	DATASET	47
5.1.1	OBTENÇÃO DOS DADOS	48
5.1.2	PRÉ-PROCESSAMENTO DOS DADOS	49
5.1.3	VISUALIZAÇÃO DOS DADOS	51
5.1.4	APLICAÇÃO DOS ALGORITMOS	55

6	CONCLUSÃO	65
7	REFERÊNCIA	66

1 INTRODUÇÃO

Com o aumento da conscientização sobre questões ambientais e a necessidade de redução de custos, o gerenciamento de energia em edifícios inteligentes tornou-se uma área importante de pesquisa e desenvolvimento. O uso de tecnologias avançadas para gerenciamento de energia em edifícios inteligentes tem sido uma área crescente de pesquisa e desenvolvimento. Isso se deve ao aumento da conscientização ambiental e à necessidade de reduzir os custos de energia. A eficiência energética em edifícios é um fator importante não apenas para preservar o meio ambiente, mas também para melhorar a eficiência econômica.

Edifícios inteligentes são construções projetadas para serem altamente eficientes em termos de energia e recursos, com sistemas integrados de automação e controle. O gerenciamento de energia em edifícios inteligentes envolve o uso de tecnologias avançadas, tais como sensores, dispositivos de controle e inteligência artificial, para monitorar e controlar o uso de energia em tempo real.

No entanto, apesar do potencial de melhorias significativas na eficiência energética, a implementação de sistemas de gerenciamento de energia eficientes e escaláveis ainda é um desafio. O objetivo deste trabalho é desenvolver um sistema de gerenciamento de energia eficiente e escalável para edifícios inteligentes, a fim de melhorar a eficiência energética e reduzir os custos de energia.

A metodologia incluirá a revisão da literatura existente sobre gerenciamento de energia em edifícios inteligentes, seguida pela concepção e implementação do sistema de gerenciamento de energia. O sistema será avaliado quanto à eficiência energética e facilidade de uso em um ambiente simulado, e a discussão incluirá uma análise comparativa com outros sistemas de gerenciamento de energia existentes.

2 OBJETIVOS

O objetivo deste trabalho é projetar e implementar um sistema de gerenciamento de energia para edifícios inteligentes, com o objetivo de reduzir o consumo de energia e os custos de energia. Além disso, o sistema deve ser escalável e fácil de usar.

2.1 OBJETIVOS ESPECIFICOS

Desenvolver um sistema de gerenciamento de energia para edifícios inteligentes que seja capaz de otimizar o uso de recursos energéticos e contribuir para a redução do impacto ambiental causado pelo consumo excessivo de energia em edifícios. Além disso, este trabalho visa investigar as possibilidades de utilização de tecnologias de IoT, aprendizado de máquina e análise de dados para melhorar a eficiência energética em edifícios.

Para atingir este objetivo, este trabalho se propõe a realizar as seguintes atividades: revisão bibliográfica dos principais estudos relacionados ao gerenciamento de energia em edifícios inteligentes; análise de requisitos para identificar as necessidades dos usuários e estabelecer as especificações técnicas do sistema; desenvolvimento do sistema de gerenciamento de energia para edifícios inteligentes, com ênfase na utilização de tecnologias de IoT, aprendizado de máquina e análise de dados; validação do sistema através de simulações e avaliações com usuários finais; e avaliação da eficiência e da eficácia do sistema.

3 METODOLOGIA

A metodologia utilizada para o desenvolvimento do sistema de gerenciamento de energia para edifícios inteligentes seguiu uma abordagem sistemática e multidisciplinar. A primeira etapa consistiu na revisão bibliográfica, que foi realizada com o objetivo de identificar as principais tendências e desafios no desenvolvimento de sistemas de gerenciamento de energia para edifícios inteligentes.

Na segunda etapa, foi realizada a análise de requisitos, com o objetivo de identificar as necessidades dos usuários e estabelecer as especificações técnicas do sistema. Para isso, foram realizadas entrevistas com especialistas no setor de gerenciamento de energia e edifícios inteligentes, bem como com usuários finais.

Na terceira etapa, foi desenvolvido o sistema de gerenciamento de energia para edifícios inteligentes. O sistema foi desenvolvido utilizando tecnologias de IoT, aprendizado de máquina e análise de dados. A implementação do sistema foi realizada em duas fases: a primeira consistiu na implementação das funcionalidades básicas, enquanto a segunda fase consistiu na implementação das funcionalidades avançadas, como a previsão de picos de consumo de energia e a otimização do uso dos recursos energéticos.

Na quarta etapa, foi realizada a validação do sistema. A validação foi realizada através da realização de simulações em um ambiente controlado, com o objetivo de avaliar a eficiência e a eficácia do sistema. Além disso, foram realizadas avaliações com usuários finais, com o objetivo de obter feedback sobre a facilidade de uso e a satisfação dos usuários.

Em resumo, a metodologia utilizada para o desenvolvimento do sistema de gerenciamento de energia para edifícios inteligentes seguiu uma abordagem sistemática e multidisciplinar, com ênfase na análise de requisitos, desenvolvimento, validação e avaliação do sistema.

4 REFERENCIAS BIBLIOGRAFICAS

A revisão bibliográfica incluirá estudos de autores como Kosonen et al. e Lu et al., que têm contribuído significativamente para a área de gerenciamento de energia em edifícios inteligentes. Além disso, serão incluídos estudos que abordam a eficiência energética em edifícios inteligentes e a facilidade de uso de sistemas de gerenciamento de energia.

4.1 INTERNET DAS COISAS (IoT)

A Internet das Coisas (IoT) é uma tecnologia emergente que tem recebido crescente atenção de pesquisadores e profissionais em todo o mundo. A IoT se baseia na conectividade de objetos cotidianos à Internet, permitindo que eles transmitam e recebam dados em tempo real. Isso abre novas possibilidades para a automação, monitoramento e análise de informações relacionadas a tarefas cotidianas, como o gerenciamento de recursos domésticos, saúde, segurança e transporte.

De acordo com pesquisas, a IoT tem o potencial de transformar significativamente a forma como as pessoas vivem e trabalham, tornando a vida mais fácil, eficiente e segura. Alguns dos benefícios da IoT incluem:


- **Melhoria da eficiência:** A IoT permite a automação de tarefas e processos, reduzindo o tempo e esforço necessários para realizá-los.
- **Monitoramento em tempo real:** A IoT permite o monitoramento em tempo real de informações e eventos, o que pode ser particularmente útil em aplicações como saúde e segurança.
- **Personalização:** A IoT permite a personalização de experiências, adaptando-se aos gostos e necessidades individuais de cada usuário.
- **Análise de dados:** A IoT permite a coleta, armazenamento e análise de grandes volumes de dados, o que pode ser usado para melhorar a eficiência e tomar decisões informadas.

A ideia é tornar o mundo físico e o digital em um só, pelos dispositivos que se comunicam entre si, os data centers e a computação em nuvem. Essa tendência de conectar objetos é discutida desde 1991, quando a conexão TCP/IP e a internet começaram a se popularizar. Bill Joy, cofundador da Sun Microsystems, pensou sobre a conexão dispositivo-dispositivo (D2D – *Device to Device*), tipo de ligação que faz parte de um conceito maior, o de “várias webs”. Já em 1999, Kevin Ashton do MIT propôs o termo “Internet das Coisas” e dez anos depois escreveu o artigo “A coisa da Internet das coisas” para o RFID Journal (ZAMBARDA, 2015, s.p.).

A primeira geração de dispositivos IoT foi limitada e consistia principalmente em sensores e atuadores simples. No entanto, com o aumento da capacidade de processamento e a popularização da internet, os dispositivos IoT começaram a ficar mais avançados e acessíveis.

Em 2003, a RFID (identificação por radiofrequência) foi incorporada aos dispositivos IoT, permitindo que os objetos fossem identificados sem contato físico. Este foi um marco importante na história do IoT, pois permitiu que os dispositivos pudessem ser monitorados e controlados remotamente.

Figura 1: Representação de integrações do IoT



Fonte: Pexels

Como exemplo de aplicação da IoT, a fabricante de elevadores Thyssenkrupp com a Microsoft desenvolveram um sistema inteligente e online para monitorar os elevadores através de callcenters e técnicos. O software funciona em grandes redes de computadores e de mesa e portáteis, além de ser executado em um aplicativo para tablets com Windows. Nos dias de hoje são muitos os objetos conectados: geladeiras, óculos, elevadores e carros. A rede pode intervir em pequenos *gadgets* ou em infraestruturas complexas, diante disso vêm surgindo iniciativas, que envolvem grandes empresas para unificar a internet das coisas. A fabricante de computadores Dell, e as empresas Samsung e Intel, por exemplo, se uniram em julho de 2014 para exatamente padronizar as conexões, em um grupo chamado “Consórcio de Interconexão Aberta” (OIC – *Open Interconnect Consortium*). A proposta é criar um protocolo comum para garantir o bom funcionamento da conexão entre os mais variados dispositivos. Essa não é a única iniciativa neste sentido, em dezembro de 2013 foi arquitetado o grupo Allseen Alliance, que tem 51 empresas participantes, entra as quais gigantes como LG, Panasonic, Qualcomm, D-link e Microsoft (ZAMBARDA, 2015, s.p.), visando integrar os dispositivos de edifícios inteligentes, assim como aumentar a conectividade, sensores e segurança, pode trazer muitos benefícios, de operacionais à experiência dos usuários. Para alcançar esses objetivos, os edifícios inteligentes agregam a vantagem da IoT para gerar, analisar e transmitir dados (INTEL CORPORATION, 2015, s.p.).

4.2 SMART HOMES

O conceito de casa automatizada foi concebido 80 anos antes, com várias limitações técnicas. Recentemente, com o advento da popularização de conexões de internet e o surgimento da tecnologia *wireless*, dispositivos inteligentes e conectados são agora realidade. Concebida para trazer melhor qualidade de vida ao usuário final, uma casa inteligente é projetada para realizar ou distribuir um número de serviços dentro e fora da construção através de uma rede de dispositivos interconectados. Enquanto que uma conexão de internet de alta velocidade não seja necessária para todos os aparelhos instalados na habitação, a total funcionalidade de uma casa inteligente depende da


disponibilidade de acesso permanente à internet. Há muitas definições que podem ser atribuídas ao conceito de casa inteligente, e esse conceito muda conforme o tempo e a tecnologia avança (SORRELL, 2014, p. 2).

A IoT é a tecnologia que vem para popularizar a “Inteligência”. Será a responsável por tornar realidade qualquer casa inteligente, as denominadas *Smart Homes*. A IoT irá possibilitar que todos os dispositivos eletrônicos de um ambiente possam se conectar à internet e entre si. A famosa firma de consultoria Gartner Inc. (2014, s.p.), em um estudo afirma que “uma típica residência familiar, em um mercado IoT consolidado, passará a ter mais de 500 dispositivos inteligentes por volta de 2020”.

O número de dispositivos dotados de inteligência em uma casa padrão crescerá de forma lenta por pelo menos essa década devido a muitos dispositivos domésticos serem trocados de forma descoordenada. No entanto, uma casa inteligente “madura” não irá existir até 2020 ou 2025, produtos inteligentes domésticos já começam a ser produzidos e as primeiras oportunidades de negócios estão a surgir (GARTNER, 2014, s.p.).

A tecnologia *wireless* será um ponto chave na conectividade entre os aparelhos e a edificação, porém não será a única tecnologia a dominar. Wi-fi, bluetooth, Zigbee, celular e várias outras tecnologias irão encontrar lugar em um ambiente inteligente. Por conta desse cenário, todas essas tecnologias necessitarão de meios de se comunicarem através de protocolos e normas. A maioria dos equipamentos será portátil e não possuirão acesso direto a suprimento de energia por meio de fios, assim muitos fabricantes de baterias irão lucrar com as casas inteligentes como desenvolvedores de fornecimento e armazenamento de energia assim como recarga sem fio (GARTNER, 2014, s.p.).

Figura 2: A casa inteligente




Fonte: CORINNE (2015, s.p.)

Segundo estudo de 2014 da empresa sueca Berg Insight, o número de casas inteligentes na Europa e América do Norte chegou aos 10,6 milhões em 2014. O mercado norte americano registrou um crescimento de 70% no ano passado, o que corresponde a 7,9 milhões de *Smart homes* (SMARTBUILDINGS, 2015, s.p.).

A Figura abaixo demonstra a comparação de números de casas inteligentes na Europa e na América do Norte, a América do Norte é o maior e mais avançado mercado de casas inteligente no mundo. O crescimento deverá se manter nos próximos anos e elevar o número de residências desse tipo nos Estados Unidos e Canadá para 38,2 milhões em 2019. Já o mercado europeu está dois ou três anos atrás do americano tanto em termos de penetração como de maturidade. No final do ano passado existiam 2,7 milhões de *Smart Homes* (SMARTBUILDINGS, 2015, s.p.).

Figura 3: Número de casas inteligentes Europa x América do Norte.



Fonte: SMARTBUILDINGS (2015, s.p.).

Entre os produtos de maior sucesso no setor, estão os termostatos inteligentes, sistemas de segurança, lâmpadas inteligentes, câmeras ligadas em rede e sistemas de áudio multi-sala de empresas como Nest, Ecobee, Philips, D-link entre outros (SMARTBUILDINGS, 2015, s.p.).

4.3 EDIFÍCIOS INTELIGENTES (EI)

Segundo Neves (2002), para o IBI – Intelligent Buildings Institute, os edifícios inteligentes são aqueles que oferecem um ambiente produtivo e econômico através da otimização de quatro elementos básicos: Estrutura, Sistemas, Serviços e Gerenciamento: bem como das inter-relações entre eles.

Para Frazatto (2000), “Edifício Inteligente” é aquele que incorpora dispositivos de controle automático aos seus sistemas técnicos e administrativos. Conforme Messias (2007) um Edifício “Inteligente” pode ser definido como sendo aquele que promove a transferência de dados de um sistema para outro, Intercursos, se aplicam processos e tecnologias, de forma apropriada para satisfazer as necessidades dos proprietários e dos ocupantes.

A IoT em edifícios inteligentes pode ser aplicada ao BAS (sistemas de automação do edifício), e com isto, todos os sistemas prediais (elétrico,

iluminação, ar-condicionado, rede de dados, etc.) podem conversar entre si e tomar decisões de forma autônoma (dentro de um escopo de atividades pré-programadas) relativo a cada um e em função das informações coletadas em outros sistemas. Assim os resultados são inteligentes e integrados, o que pode inclusive contar com sistemas de manutenção preventivos, baseados em históricos, estatísticas e experiências adquiridas, somado aos dados coletados dos sensores, para um melhor desempenho (ALLTOMATIC, 2015, s.p.). Com um smartphone, os usuários cadastrados nas instalações podem, por exemplo, controlar a iluminação e climatização de acordo com suas necessidades. Da mesma forma, detectada a ausência de pessoas em determinado cômodo, o sistema desliga ou reduz a atividade dos equipamentos e com isso poupa energia (ALLTOMATIC, 2015, s.p.). A IoT pode permitir através dos mecanismos de automação, diminuir a demanda de energia elétrica nos períodos de maior consumo, o que gera enorme vantagem para as concessionárias, visto que não se torna necessário uma expansão da rede instalada (ALLTOMATIC, 2015, s.p.).

4.3.1 Els PELO MUNDO

A sede da Environmental Systems Inc. em Brookfield, Wisconsin é considerada um dos mais inteligentes edifícios do mundo, automatizado de tal forma que até os extintores de incêndio são controlados pela internet. Esse edifício comercial é um grande exemplo de alta tecnologia em construções e possui sistemas que reduzem significativamente seus custos operacionais. A construção recebeu nota 98 pela Energy Star, com redução de 33 por cento nos custos em comparação à sede anterior, mesmo o novo edifício sendo 10 mil metros quadrados maior (ARCHITIZER, 2014, s.p.).

Desenvolvido para reduzir custos de operação e impacto ambiental, o edifício foi construído para receber a certificação LEED, ao utilizar aplicações inovadoras de tecnologia de ponta nos sistemas para gerenciamento da construção e design. O lobby do edifício conta com monitores de tela fina que mostram em tempo real informações sobre a performance. Esses parâmetros incluem medições relacionadas à energia, sistema de ar-condicionado (HVAC),

luzes e tomadas. O sistema de alarme é conectado ao BAS (*Building Automation System*), enquanto o sistema monitora os extintores de incêndio e assegura que eles possuem a pressão adequada, estão instalados corretamente e não há obstruções (ARCHITIZER, 2014, s.p.).

Figura 4: Sede da Environmental Systems Inc.



Fonte: ARCHITIZER (2014, s.p.)

Projetado pelo escritório de arquitetura *Aedas Architects*, o diferencial deste edifício consiste de um sistema dinâmico e inovador de sombreamento interno projetado para reduzir a insolação em 50%. A fachada do empreendimento foi inspirada no tradicional sistema de treliças árabes, chamadas *Mashrabiya* (Architizer.com, 2014, s.p.).

Enquanto a maioria dos prédios no oriente médio é desenvolvido para lidar com o ganho solar em uma região quente e árida, as torres Al-Bahr têm seu design diferenciado por conta de sua fachada. No projeto das torres, o ponto chave foi considerar o renovado interesse em eficiência energética em Abu Dhabi, além do desejo de se utilizar tecnologia moderna para a realização do empreendimento. Uma forma circular foi proposta para essa eficiência e reduzir a área de superfície, que foi refinada frequentemente até se obter sua forma final. O processo de design foi realizado por meio de parâmetros e algoritmos de computador (CTBHU, 2013, s.p.).

Os componentes móveis da fachada são compostos de painéis semitransparentes de PTFE (politetrafluoretileno) combinados em um esquema

semelhantes a guarda-chuvas. Cada painel abre e fecha conforme a incidência direta solar nos painéis, o que permite que a luz solar penetre indiretamente enquanto se bloqueia os raios solares responsáveis pelo calor. Dessa forma o sistema aumenta o conforto térmico e reduz a necessidade de luz artificial no interior (CTBHU, 2013, s.p.). Os jardins de inverno internos estão localizados ao longo da fachada sul do edifício, que em conjunto com o exterior ajuda a aliviar os efeitos da exposição solar. Eles também servem para o conforto dos usuários, que utilizam os espaços para reuniões ou pausas. Na Figura 30 é possível perceber a fachada diferenciada que é inspirada nas treliças árabes.

Figura 5: Torres Al-Bahr.



Fonte: CTBHU (2013, s.p.).

O Eldorado Business Tower (Figura 34), edifício com uma arquitetura marcante e imponente, localizado na Av. das Nações Unidas, região da Marginal Pinheiros em São Paulo, obteve o selo LEED Platinum. Os principais resultados que demonstram a alta performance do edifício são (IBDN, 2012, s.p.):

- 33% de economia no consumo de água potável, comparado ao padrão norte-americano;
- 100% de economia de água potável para irrigação;
- 18% de economia no consumo de energia;
- 74% de todo resíduo gerado na obra foi desviado de aterros;
- 30% de todo material empregado é de origem reciclada;
- 50% de todo material adquirido é de origem local;
- 95% de toda madeira é certificada pelo FSC (Forest Stewardship Council);
- 25% de redução da vazão e volume de água lançada na rede pública durante as chuvas.

Figura 6: Edifício Eldorado Business Tower.



Fonte: IBDN (2012, s.p.).

4.3.2 CARECTERISTICAS DOS EI

Conforme Messias (2007), os edifícios inteligentes são caracterizados por possuírem um sistema de controle central para otimizar certas funções inerentes à sua operação e administração. Além de segurança, oferecem conforto ambiental (controle de temperatura e umidade); conforto visual (diversas opções de iluminação); conforto acústico (som ambiente) e comunicações (instalações de redes, telefonia interna e externa).

Para Messias (2007), os edifícios inteligentes podem oferecer ao usuário a possibilidade de utilizar um dispositivo de segurança, chamado controle de acesso. Este dispositivo na realidade faz parte de um sistema que pode integrar a portaria de acesso da edificação, controle de fluxo de pessoas, racionalização do uso de energia elétrica, além de dispositivos de conforto. O morador de posse de um cartão magnético ou um cartão de proximidade consegue o acesso à edificação com o uso deste cartão na portaria. Ao passar este cartão de acesso, seus dados são verificados e sendo ele usuário cadastrado desta edificação, o seu acesso é permitido com o destravar da porta, mas enquanto todo este processamento é realizado, o sistema aciona o elevador que chegará a portaria já programado para deslocar ao andar deste usuário. Também é acionado de forma automática o sistema de climatização da sala ou apartamento deste usuário, bem como a iluminação dos corredores que o mesmo irá trafegar para chegar a sua sala e também a iluminação do hall de sua sala ou apartamento.

Segundo Neves (2002), os edifícios inteligentes têm como características:

- Dispõem dos serviços oferecidos pelas novas tecnologias da informação;
- Integram os serviços em uma rede de comunicações;
- Realizam o controle e o gerenciamento por meio de um ou vários computadores interligados.

4.3.3 AUTOMAÇÃO RESIDENCIAL

Sistemas de automação residencial ou também “BUILDING AUTOMATION SYSTEMS” (BAS), compreendem o uso de equipamentos eletrônicos que automaticamente realizam funções específicas na construção. Um BAS pode ser definido como um controlador automático de um ou mais sistemas principais em uma edificação, como por exemplo: HVAC, luz, energia, elevadores, segurança etc. De modo direto, um BAS serve para integrar demais sistemas domóticos em uma edificação (LER, 2006, p. 21).

4.3.3.1 HVAC

Os sistemas HVAC acondicionam o clima em um edifício. Em outras palavras, HVAC controla a temperatura ambiente, umidade, fluxo de ar e, sobretudo a qualidade do ar. Um sistema típico agrega o ar externo, mistura com

o ar entrando ou saindo do edifício, filtra o ar e depois o canaliza para um aquecedor ou refrigerador para adquirir a temperatura adequada, por fim distribui esse ar para todas as partes da construção (SINOPOLI, 2010, p. 31).

Esses sistemas não tornam apenas o interior das edificações mais confortáveis, saudáveis e melhor habitável para seus ocupantes, eles também usam uma grande porção da energia consumida do edifício e implica custos de utilização. Para manter a qualidade do ar interior, o sistema HVAC deve responder a uma grande variedade de fatores dentro e fora do edifício (clima, hora do dia, diferentes espaços dentro do edifício e como o são ocupados, etc.), enquanto simultaneamente otimiza as operações com o consumo de energia. É um sistema essencial no controle de fumaça em caso de incêndio (SINOPOLI, 2010, p. 32).

O desenvolvimento de sensores e softwares para o controle de funcionamento da climatização permitiu um sistema de aquecimento independente por setores, fazendo o uso de válvulas eletrotérmicas com consumo reduzido. Um dos maiores objetivos da climatização é proporcionar o maior conforto possível. O sistema pode ser controlado pelo utilizador manualmente, por celulares ou até da internet. Pode haver a programação dos horários para ativar ou desativar os equipamentos HVAC para poupar energia. Os equipamentos funcionam de acordo com os horários, presença de pessoas e temperatura exterior (BARROS, 2010, p. 47-48).

Um sistema HVAC com apenas um único controle de termostato, serve uma zona de “carregamento térmico”. A maioria dos edifícios possuem múltiplas zonas, com o ar sendo distribuído a cada zona específica de acordo com sua necessidade térmica. Em uma comparação mais simples, duas casas possuem duas zonas, por exemplo, uma sendo o térreo e outra o andar superior, cada uma com um sistema de aquecimento e resfriamento do ar. O andar superior geralmente possui um maior carregamento térmico que o inferior e requer mais resfriamento. (NASCIMENTO, 2017, p.52-53)

Segundo Angel (1993, p.51-52 apud Barros, 2010, p. 48), o sistema pode proporcionar:

- Otimização em relação ao meio externo;

- Auto adaptação, levando em conta o tempo de resposta dos aparelhos;
- A gestão de ambientes individualizados, cada um com um controle de temperatura;
- Controle à distância da temperatura interna da edificação;
- Alternar para um nível menor de consumo, quando não houver ocupantes no ambiente;
- Desativar o aquecimento ou ar-condicionado se alguma janela estiver aberta.

4.3.3.2 CONTROLE DE ILUMINAÇÃO

A iluminação é necessária para prover visibilidade aos ocupantes, estética dos ambientes e para segurança. É estimado que a iluminação consumisse de 30% a 40% da eletricidade usada no edifício. Iluminação desnecessária e descontrolada em uma construção não apenas desperdiça energia, mas também aumenta os custos de utilização. A iluminação pode afetar outros sistemas tecnológicos da construção, por exemplo, de acordo com sua utilização pelo custo de refrigeração dos espaços onde a iluminação aumenta a temperatura interna (SINOPOLI, 2010, p. 47).

Um sistema de controle de iluminação providencia aos habitantes a iluminação adequada de uma maneira eficiente, consistente de acordo com a necessidade. A necessidade de luz em um edifício varia de acordo com o tipo, distribuição dos espaços internos, hora do dia e a densidade de ocupantes. Consequentemente, as funções e estratégias de controle refletem essas variáveis e primeiramente envolvem segundo SINOPOLI (2010, p. 48):

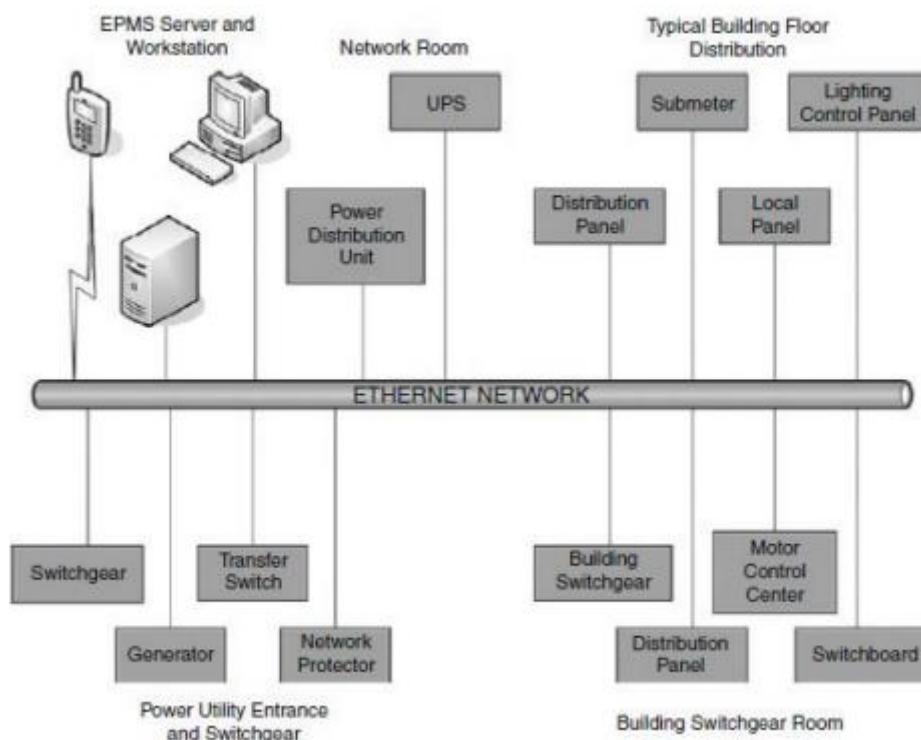
- Agendamento: um sistema de controle deve possuir um agendamento predeterminado onde as luzes são ligadas e desligadas.
- Sensores de ocupação: para espaços onde a ocupação é difícil de estimar (lobbys e espaços comuns), as luzes podem ser controladas por sensores de movimento ou ocupação.
- Luz diária: para reduzir a necessidade e o custo de utilizar luz artificial, um sistema de controle pode utilizar o máximo de luz natural quanto possível. A isso se dá o nome de “Daylight harvesting” ou “daylighting”

- Fachadas de vidro: fachadas “espectralmente seletivas”, desenvolvidas para climas quentes com grande quantidade de radiação solar, funcionando como um filtro, dissipando frequências de luz que produzem calor enquanto minimiza a perda de transmissão de luz.

4.3.3.3 CONTROLE DE ENERGIA ELETRICA

Um sistema de gerenciamento de energia elétrica de um edifício (EPMS – Electric Power Management System) monitora a distribuição de energia para uso e qualidade. O EPMS, em conjunto com o sistema HVAC e o sistema de iluminação, são partes integrais de todo o gerenciamento de energia visando controlar o uso e custos. O EPMS é uma ferramenta no gerenciamento e garantia de qualidade da energia, sendo uma fonte de energia livre de surtos, quedas e interrupções que afetem a segurança e confiabilidade da edificação (SINOPOLI, 2010, p. 59). O EPMS monitora a distribuição elétrica, gerando dados sobre o consumo de energia em setores específicos ou como um todo, qualidade da energia e emite alerta em uma eventual situação. Isso é baseado nos dados que o sistema adquire e que pode ajudar em definir e até mesmo iniciar o planejamento para redução do consumo e custo. O sistema “derrama” energia e é acionado por fatores determinados assim como certos níveis de energia demandada na utilização ou uma hora particular do dia, onde o consumo é alto. O EPMS pode gerenciar alerta, calcular tendência de uso, diagnosticar problemas e agendar manutenções, além de fornecer dados sobre o consumo de energia para um usuário específico ou inquilinos (SINOPOLI, 2010, p. 60). Tipicamente, esse sistema monitora a entrada de energia em uma edificação, campus, comutadores, protetores de rede elétrica, quadros de distribuição, geradores, entre outros.

Figura 7: EPMS.



Fonte: Sinapoli (2010,p.60)

4.3.3.4 GERENCIAMENTO DO EDIFÍCIO

Um sistema de gerenciamento do edifício (FMS – Facility Management System) é o sistema central para um edifício inteligente que agrega parte das funções operacionais de uma edificação convencional com sistemas tecnológicos prediais. O FMS é tipicamente um sistema de servidor central com uma estação de trabalho para um operador que pode ser auxiliado por equipamentos wireless (SINOPOLI, 2010, p. 129).

O acesso na maioria das FMS pode ser feito através da internet. A FMS geralmente opera com um protocolo Ethernet IP padrão, através de infraestrutura por cabos além da infraestrutura padrão de sistemas operacionais e banco de dados. A definição de FMS pode ser confusa, especialmente em comparação com um BAS. Uma FMS tem seu foco no processo de gerenciamento da edificação, é uma ferramenta que auxilia as operações de gerenciamento, estoque, suprimentos e obtenção destes. Esses sistemas são

geralmente ofertados por empresas com foco em aplicações específicas para o gerenciamento da edificação ou mais amplamente produtos que auxiliem os negócios como recursos humanos, finanças, compras e etc (SINOPOLI, 2010, p. 130).

Já um BAS é focado na parte operacional dos sistemas de um edifício inteligente, principalmente segurança dos usuários e os sistemas automatizados. Um BAS é ofertado tipicamente por fornecedores de automação residencial e de sistemas de segurança, este pode integrar os demais sistemas e controles da construção, adquirir dados de equipamentos ou acessórios específicos, gerar alertas e permite aos operadores criarem configurações e agendamentos do sistema, entre inúmeras outras (SINOPOLI, 2010, p. 130).

4.3.3.5 EFICIÊNCIA ENERGÉTICA

Um sistema que valorize a eficiência energética exclusivamente em benefícios no curto prazo, pode conduzir a uma concepção do bem-estar imediato sem que haja medidas para a continuidade do conforto social a longo e médio prazo, enquanto que uma ação baseada em manter os índices de conforto e atividade utilizando técnicas eficientes de geração, transporte e consumo de energia, pode manter e inclusive incrementar tanto o conforto da sociedade quanto a produtividade industrial do país, diminuindo o número de megawatts consumidos. A redução do consumo fundamentado na eficiência energética implica em permitir um maior acesso da população à situação de conforto desejada, enquanto que a redução dos custos de produção aumentaria a competitividade da indústria, o que a transforma em um fator dinamizador da economia de um país, razão pela qual a área das edificações tem um potencial enorme no campo da eficiência energética. (FERRER e GARRIDO, 2013,p. 2).

Em 2012, o consumo de energia elétrica no Brasil foi de 480,12 TWh, sendo que as edificações representaram um percentual de 46,7% (224,20 TWh) desse consumo, o setor residencial foi responsável por 23,3% (111,97 TWh); o setor comercial 15,45 (74,05 TWh) e o setor público, 8% (38,17 TWh). Em uma indústria, a maior parte da energia elétrica consumida provém das máquinas e

motores, o que limita a atuação da arquitetura e engenharia no sentido de economizar energia. (LAMBERTS, DUTRA e PEREIRA, 2014, p. 16)

Entende-se por Eficiência Energética em uma edificação, a adequação da construção ao entorno para reduzir sua demanda energética, assim como na utilização da energia solar ou complementares para suprir os requerimentos energéticos dos edifícios com relação ao aquecimento, refrigeração e iluminação com a finalidade de reduzir substancialmente consumo energético de energia convencional. Ao reduzir a demanda de energia, diminuem consequentemente as emissões de CO₂ e outros agentes de poluição atmosférica. (NASCIMENTO, 2017, p. 61-62)

Segundo (FERRER e GARRIDO, 2013, p. 2), os objetivos que devem ser atingidos com a eficiência energética são:

- Propiciar condições adequadas para conseguir edifícios mais eficientes do ponto de vista energético tanto em novas obras, quanto em já existentes, considerando o clima ao redor sem ser alheio a arquitetura do edifício;
- Favorecer a utilização dos recursos naturais renováveis para o condicionamento dos edifícios, também conhecido como uso de técnicas naturais de condicionamento, considerando os componentes, as técnicas construtivas e a localização do edifício;
- Integrar os sistemas solares ativos de aquecimento térmico ou de produção de eletricidade como outro componente do edifício.

4.4 GERENCIAMENTO DE ENERGIA

Chen, Lyu e Chen (2018), propõem um sistema de gerenciamento de energia baseado na Internet das Coisas (IoT) para edifícios inteligentes. O sistema é composto por dispositivos IoT, como sensores, atuadores e gateways, que coletam dados em tempo real sobre o uso de energia e o estado do ambiente. Os dados são então processados e utilizados para otimizar o uso de energia. A implementação do sistema foi avaliada em uma edificação de escritórios, e os resultados mostraram que o sistema foi capaz de melhorar significativamente a eficiência energética.

S.Lee e J.Lee (2017), revisam os sistemas de gerenciamento de energia em edifícios, incluindo sua evolução histórica e as tendências atuais. Eles também apresentam uma análise comparativa de diferentes tipos de sistemas, incluindo sistemas baseados em IoT, sistemas baseados em modelos matemáticos e sistemas baseados em aprendizado de máquina. A revisão inclui também uma discussão sobre as barreiras e desafios para a implementação de sistemas de gerenciamento de energia eficientes e escaláveis.

J.Kim, H.Kim e D.Lee (2017), propõem um sistema de gerenciamento de energia baseado em mineração de dados e redes neurais artificiais para edifícios inteligentes. O sistema é capaz de aprender automaticamente padrões de uso de energia a partir de dados históricos, e utiliza esses padrões para prever o uso futuro de energia. O sistema também é capaz de realizar ajustes dinâmicos no uso de energia para atingir metas de eficiência energética. A implementação do sistema foi avaliada em um ambiente simulado, e os resultados mostraram uma melhoria significativa na eficiência energética.

4.4.1 ISO 50001

Publicada no dia 15 de junho de 2011 pela Internacional Organization for Standardization e lançada para a sociedade brasileira no dia 7 de julho de 2011, a ABNT NBR ISO 50001: Sistema de gestão da energia – Requisitos com orientações para uso é uma norma com o propósito de permitir o estabelecimento de sistemas e processos do desempenho energético em todos os tipos de organizações (ABNT, 2013).

A norma especifica os requisitos para uma organização estabelecer, implementar, manter e melhorar um Sistema de Gestão Energética, que considere uma abordagem sistêmica para alcançar a melhoria contínua do desempenho energético. Ela é baseada nos mesmos elementos encontrados nas demais normas, 27 sendo compatível com os selos ISO 9001 (qualidade de gestão) e ISO 14001 (gestão ambiental).

Com três focos principais – eficiência energética, uso da energia e consumo de energia – a ABNT NBR ISO 50001:2011 recomenda às

organizações vários procedimentos como, por exemplo, adoção de critérios de eficiência na compra de equipamentos, conscientização e treinamento sobre os aspectos vinculados ao uso adequado da energia (ABNT, 2013).

A expectativa diante de uma aplicação global é obter maior disponibilidade de suprimento, melhorar a competitividade de organizações e reduzir o impacto nas mudanças climáticas.

Através de ações por todo o mundo, a norma tem potencial de causar um impacto positivo de 60% no consumo final. Isso porque a melhoria contínua do desempenho energético das organizações, um dos objetos dessa ISO, implica diretamente em uma diminuição do consumo de energia (ABNT, 2013).

Para as empresas, a implementação da norma contribui com impactos positivos no cenário de competitividade industrial. Um bom sistema de gestão energética traz a redução acentuada nos custos de produção, já que os desperdícios de energia e perdas em sistemas não monitorados representam custos invisíveis nas faturas de energia. A norma também permite a exploração de marketing, uma vez que a redução do consumo implica diretamente na diminuição de impactos ambientais

4.4.2 INDICADORES DE EFICIÊNCIA ENERGÉTICA (IEE)

A avaliação do desempenho ambiental de uma organização é uma atividade complexa e difícil de quantificar, porém necessária. Requer, a partir do SGE, algum método que relacione as questões ambientais com as atividades econômicas por unidades de medidas quantificáveis, ou seja, a utilização de indicadores de eficiência energética (IEE) que realizem o controle das informações obtidas pelos gestores (NILSSON, 2007, p. 87). Conforme o contexto energético vivenciado atualmente, os IEE apresentam-se como uma importante ferramenta avaliativa do ser humano. A sua elaboração, de âmbito global ou local, é feita a partir de uma associação dos tipos de energia com os fatores econômicos, ambientais, sociais e tecnológicos. Faz-se um cruzamento de duas ou mais informações para se obter um auxílio nas análises tanto energéticas como sociais, e deste modo, estimar o nível de desenvolvimento da

sociedade e permitir assim um monitoramento das políticas energéticas (ROMÉRO; REIS, 2012, p. 17).

A utilização de IEE contribui como uma ferramenta na formação de metas voltadas às políticas ambientais, nas limitações tecnológicas e de matérias-primas direcionadas à redução da demanda de energia e na conscientização do consumo energético (TAVARES; MONTEIRO, 2014). Além disso, tem como uma das principais funções a identificação das principais áreas que necessitam de uma otimização de potencial, controlando assim o fluxo energético bem como a adoção de medidas de desempenho (NILSSON, 2007, p. 95).

A seleção dos critérios e dados para a elaboração dos IEE deve ser feita cautelosamente. Seus resultados são direcionados às ações de gestão da organização, devendo-se manter a validade dos dados e uma percepção das práticas necessárias para o seu melhor desempenho dentro de suas limitações, para se evitar resultados distorcidos e não condizentes com a realidade (NILSSON, 2007, p. 89).

Deste modo, é importante manter um monitoramento das informações existentes na composição dos indicadores de modo que se tenha uma maior administração e um melhor resultado da realidade do sistema. Esse conjunto de indicadores elaborados servirão como um auxílio ao SGE, de forma que seja possível a partir de seus resultados quantitativos, um diagnóstico, controle e a identificação das necessidades presentes nas organizações para ser aperfeiçoado seu desempenho. Não é suficiente apenas indicadores que monitoram o desempenho e apresentam resultados se esse não estiver atrelado às atividades de gestão (MARTINS; NETO, 1998).

A qualidade do meio ambiente em uma organização pode ser determinada a partir das informações disponibilizadas pelos indicadores de condição ambiental (ICA). Como muitos fatores influenciam para os problemas ambientais existentes, a utilização dos dados obtidos pelos ICA poderá contribuir como uma orientação na determinação de prioridades para a elaboração dos indicadores específicos, tanto em relação aos problemas ambientais como nas particularidades empresariais (NILSSON, 2007, p. 92).

4.4.3 GESTÃO ENERGÉTICA E INDICADORES PARA EDIFÍCIOS.

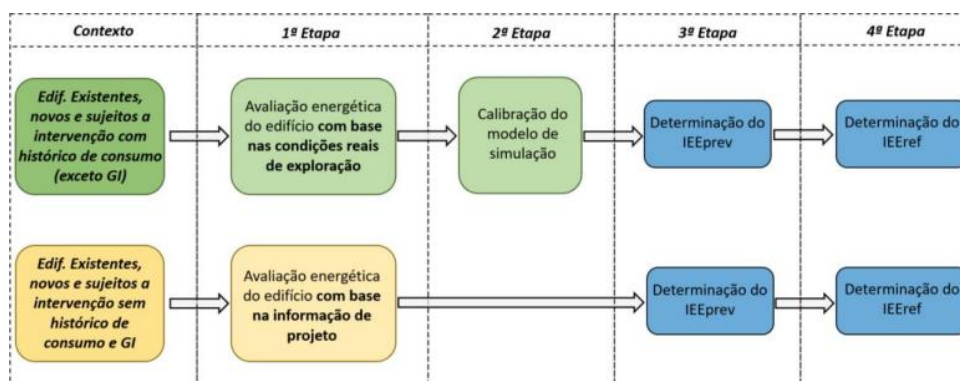
Com o desenvolvimento populacional e industrial, assim como a mudança no estilo de vida, mostra-se importante a geração de energia com direcionamento ao consumo sustentável. O panorama energético está se deslocando à produção de formas de energia mais limpas a partir da utilização de novas tecnologias, devido a necessidade de diminuição dos efeitos ambientais (DUDLEY, 2012). Torna-se fundamental um crescente desenvolvimento mundial, mas também uma redução das emissões de CO₂.

A busca por eficiência energética e a grande preocupação com as questões ambientais estão cada vez mais presentes mundialmente. Devido ao elevado custo da energia, até mesmo no Brasil, em que apresenta um mercado economicamente competitivo e uma matriz energética com vasta parcela renovável, essa preocupação se mantém. Impactos ambientais diretos ou indiretos são evidentes em fontes de energia, tanto renováveis como não renováveis (ENERGÉTICA, 2010).

O desempenho energético de um edifício de comércio e serviços é aferido através da comparação do seu Indicador de Eficiência Energética (IEE) com o de um edifício de referência. O IEE corresponde ao somatório de todos os consumos do edifício convertidos em energia primária por unidade de área aos quais se subtrai a produção de origem renovável, igualmente convertida em energia primária por unidade de área. Os consumos são desagregados nos tipos “S” e “T”, contabilizando-se apenas os primeiros para efeitos de determinação da classe energética, desprezando-se os segundos para este efeito (Sce, p.5).

$$IEE = IEE_S + IEE_T - IEE_{ren} [kWh_{EP}/(m^2 \cdot ano)] \quad (1)$$

Figura 8: Procedimentos a seguir no processo de determinação dos IEE.



Fonte: SCE

1ª Etapa - Avaliação energética do edifício: é efetuada a caracterização detalhada das condições de exploração de energia do edifício ou fração, com vista a identificar os diferentes vetores energéticos e a caracterizar os consumos energéticos, de acordo com os procedimentos descritos no guia “4.2 Guia SCE – Recolha de informação (RECS)”.

2ª Etapa - Calibração do modelo de simulação (aplicável apenas a edifícios existentes, novos ou alvo de intervenção com histórico de consumo de energia e GI): resulta da comparação dos consumos de energia do edifício (por forma de energia) obtidos por simulação dinâmica com o consumo energético faturado e/ou medido por avaliação energética. O modelo de simulação a calibrar tem por base as condições reais de funcionamento do edifício identificadas na 1ª Etapa, e considera-se calibrado o modelo cujos resultados não apresentem um desvio superior a +/- 10% do consumo energético faturado e e/ou medido por avaliação energética. Esta etapa é essencial para validação dos perfis de funcionamento de todos os consumidores de energia do edifício, bem como dos perfis de ocupação. Uma calibração adequada atribui maior grau de confiança ao modelo de simulação utilizado, permitindo assim que os resultados da análise económica da implementação das medidas de melhoria sejam mais fidedignos. (Nota: Os resultados obtidos nesta etapa, referentes aos consumos energéticos do edifício, não serão considerados para efeitos da determinação do desempenho energético da fração ou edifício).

3ª Etapa - Determinação do IEEprev: Após o modelo de simulação dinâmica ter sido calibrado, tendo por base o modelo desenvolvido na 2ª Etapa, deve proceder-se por meio de simulação dinâmica à obtenção do consumo de

energia total do edifício adotando as condições previstas na tabela I.04 da Portaria n.º 349-D/2013, na sua versão mais atual. 4ª Etapa - Determinação do IEE_{ref}: Utilizando como base modelo de simulação da 3ª Etapa, deverá proceder-se à obtenção do consumo de energia total para o edifício de referência adotando as condições previstas na tabela I.07 da Portaria n.º 349 D/2013, na sua versão mais atual. Os consumos a considerar para determinação dos IEES e IEET constam na Tabela I.01 da Portaria n.º 349-D/2013 onde:

Figura 9: Consumos no IEES e IEET.

Consumos no IEE _s	Consumos no IEE _r
<ul style="list-style-type: none"> - aquecimento e arrefecimento ambiente, incluindo humidificação e desumidificação - ventilação e bombagem em sistemas de climatização - aquecimento de águas sanitárias e de piscinas - iluminação interior - elevadores, escadas e tapetes rolantes (a partir de 1 de janeiro de 2016) - iluminação exterior (a partir de 1 de janeiro de 2016) 	<ul style="list-style-type: none"> - ventilação e bombagem não associada ao controlo de carga térmica - equipamentos de frio - iluminação dedicada e de utilização pontual - elevadores, escadas e tapetes rolantes (até 31 de dezembro de 2015) - iluminação exterior (até 31 de dezembro de 2015) - todos os restantes equipamentos e sistemas não incluídos em IEE_s

Fonte: Tabela I.01 da Portaria n.º 349-D/2013

4.5 ALGORITMOS DE MACHINE LEARNING

A Inteligência Artificial (IA) é uma área da Ciência da Computação que visa criar mecanismos para que os computadores se assemelhem ao ser humano, tanto na forma de pensar quanto na de agir de maneira inteligente. A IA é um tema amplo e adaptável que se relaciona basicamente com todas as áreas do conhecimento. Nos últimos tempos, a IA tem sido objeto de trabalho por grande parte dos pesquisadores da área (GOMES, 2011).

De acordo com Makridakis (2017), o objetivo das pesquisas em IA é ensinar os computadores a pensar por si mesmos e propor soluções para atividades corriqueiras. No entanto, ainda há muitas dúvidas quanto à possibilidade de as máquinas pensarem, embora existam sinais de inteligência.

Por outro lado, as máquinas já estão oferecendo diversas melhorias para a humanidade. No passado, crises de comida, guerras e pandemias eram mais frequentes, afetando grande parte da população e causando inúmeras mortes. Graças à Revolução Industrial, o padrão de vida das pessoas melhorou, e a revolução digital, principalmente a partir da década de 1990, contribuiu para o aumento de empregos, com postos de trabalho mais atraentes e confortáveis. Dando continuidade a essas melhorias, a revolução da IA promete a expansão de riquezas. Hoje, é mais comum as pessoas morrerem por excesso de comida do que por fome, cometerem suicídios do que serem mortas por soldados e terroristas ou morrerem por idade avançada do que por doenças infecciosas (MAKRIDAKIS, 2017).

A informação é corroborada por Poola (2017), quando ele afirma que a IA de hoje está projetada para resolver pequenas tarefas como reconhecimento facial, direção de veículo autônomo, entre outras atividades menores. Mas, futuramente, poderá ser construída uma super IA abrangendo várias áreas que superem os humanos na resolução de atividades complexas. Atividades estas apontadas por Keswani (2013) como capacidade de: conhecimento e aprendizagem, fazendo com que se possa julgar e compreender relacionamentos, gerando conclusões originais.

Em relação à corrida pela liderança em IA, a China está focada em se tornar a líder mundial nessa área até 2030. A vantagem da China sobre as demais nações está relacionada ao empenho governamental e ao grande poder de inovação. Somado a esses fatores, a China possui mais de 700 milhões de usuários conectados, gerando uma enorme quantidade de dados para treinar algoritmos de IA. As políticas de incentivo do governo favoreceram inovações, e gigantes da internet, como Baidu, Tencent e Alibaba, aproveitaram a oportunidade para expandir e oferecer novas tecnologias (TSE, 2017).

O Machine Learning tem sido um campo de estudo ativo desde o final da década de 1950, mas foi somente nos últimos anos que avanços significativos foram feitos na área, permitindo a aplicação prática desses algoritmos em uma variedade de indústrias. O surgimento de tecnologias de Big Data e computação em nuvem permitiu que grandes quantidades de dados fossem processados de

maneira eficiente, tornando o Machine Learning uma ferramenta valiosa para análise de dados em tempo real e tomada de decisões baseadas em dados.

A crescente disponibilidade de dados e o aumento do poder computacional levaram a avanços significativos na eficácia dos algoritmos de Machine Learning. Por exemplo, a técnica de Deep Learning, que usa redes neurais profundas para aprender a partir de dados, tem sido especialmente bem-sucedida em áreas como reconhecimento de voz e imagem, os algoritmos de Machine Learning são amplamente usados em áreas como finanças, saúde, manufatura e marketing. Eles são usados para detectar fraudes financeiras, prever diagnósticos médicos e otimizar processos de produção, entre outras aplicações. À medida que mais e mais dados são coletados e processados, o uso de algoritmos de Machine Learning só deve crescer.

Dentre os diversos tipos de algoritmos de Machine Learning, destacam-se a regressão linear, árvore de decisão, random forest, xgboost e rede neural. Cada um desses algoritmos é projetado para resolver problemas específicos e apresenta suas próprias vantagens e desvantagens.

4.5.1 REGRESSÃO LINEAR


O modelo de regressão linear, segundo Krajewski, Ritzman e Malhotra (2009), é um dos modelos causais mais conhecidos e utilizados, que consiste de uma variável chamada de dependente estar relacionada a uma ou mais variáveis independentes por uma equação linear. Pode-se dizer em uma linguagem técnica que a linha de regressão minimiza os desvios quadrados dos dados reais. Para se obter o cálculo da equação da reta basta aplicar a seguinte equação:

$$y = a + b \quad (2)$$

Na equação acima, “y” refere-se a variável dependente e “x” a variável independente. O “a” representa interseção da linha no eixo y e b inclinação da linha. Esta fórmula estabelece a equação que identifica o efeito da variável de previsão (variável independente) sobre a demanda do produto em análise (variável dependente), isso porque se busca prever a demanda de determinado

item com base na previsão de outra variável que tenha relação com tal item. Em outras palavras, tem por objetivo encontrar uma equação linear de previsão de modo que a soma dos quadrados dos erros de previsão (beta) seja a mínima possível. Na figura 1, observa-se a formação da reta no sistema cartesiano.

Figura 10: Mínimos quadrados.



Fonte: Tubino (2007)

Para se encontrar os valores de a e b, segue a fórmula conforme descreve Gaither e Frazier (2006):

$$a = \frac{\sum x^2 \sum y - \sum x \sum xy}{n \sum x^2 - (\sum x)^2} \quad (3)$$

$$b = \frac{n \sum xy - \sum x \sum y}{n \sum x^2 - (\sum x)^2} \quad (4)$$

De acordo com as equações (3) e (4) apresentadas, o cálculo dos coeficientes a e b tem como finalidade minimizar a soma dos desvios quadrados dos dados reais da linha do gráfico. A variável n corresponde o período considerado para o estudo.

4.5.2 ÁRVORE DE DECISÃO

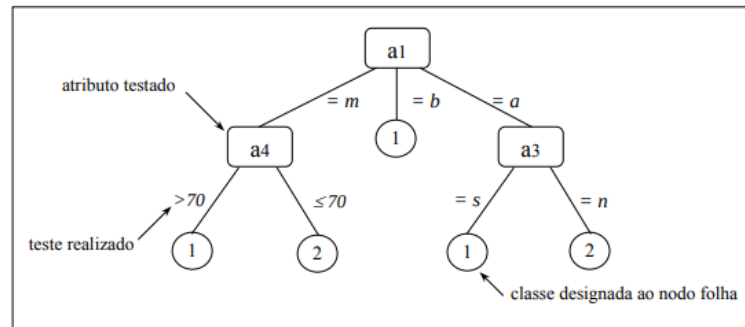
Árvores de Decisão são métodos de classificação de dados no contexto da chamada Mineração de Dados (Data Mining). Podem ser usadas em conjunto com a tecnologia de indução de regras, mas são as únicas a apresentar os resultados hierarquicamente (com priorização). Nelas, o atributo mais importante é apresentado na árvore como o primeiro nó, e os atributos menos relevantes são mostradas nos nós subsequentes.

A vantagem principal das Árvores de Decisão é a tomada de decisões levando em consideração os atributos mais relevantes, além de compreensíveis para a maioria das pessoas. Ao escolher e apresentar os atributos em ordem de importância, as Árvores de Decisão permitem aos usuários conhecer quais fatores mais influenciam os seus trabalhos. De acordo com RAGSDALE (2001), a árvore de decisão é composta por nós (representados por círculos e quadrados) interconectados por ramos (representados por linhas).

Um nó quadrado é chamado de nó de decisão porque representa uma decisão. Ramos emergindo do nó de decisão representa as diferentes alternativas para uma decisão particular. Segundo Garcia (2000), as Árvores de Decisão também consistem de: nodos (nós), que representam os atributos, e de arcos (ramos), provenientes desses nodos e que recebem os valores possíveis para esses atributos (cada ramo descendente corresponde a um possível valor desse atributo).

Nas árvores existem nodos folha (folha da árvore), que representam as diferentes classes de um conjunto de treinamento, ou seja, cada folha está associada a uma classe. Cada percurso na árvore (da raiz à folha) corresponde a uma regra de classificação. Cada nó de decisão contém um teste num atributo, cada ramo descendente corresponde a um possível valor deste atributo, cada folha está associada a uma classe, cada percurso na árvore (da raiz à folha) corresponde a uma regra de classificação, cada folha corresponde a uma região, hiper retângulo, a intersecção dos hiper retângulos é vazio e a união dos hiper retângulos é o espaço completo. (João Gama, 2002).

Figura 11:Exemplo classificador arvore de decisão.

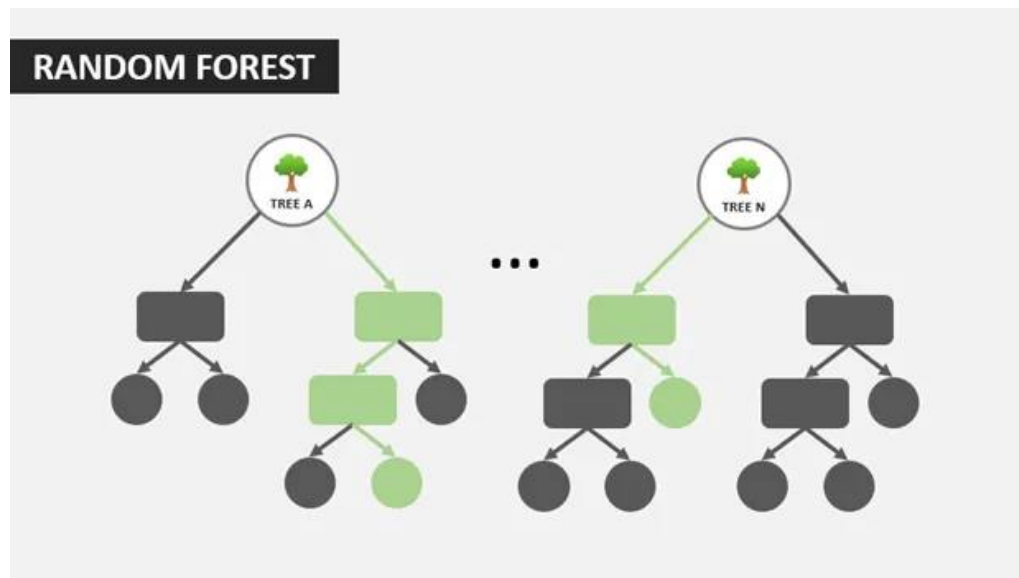


Fonte: Garcia (2000)

4.5.3 RANDOM FOREST

O nome Random Forest faz todo o sentido quando se pensa em seu funcionamento: random significa aleatório, e denota o comportamento do algoritmo ao selecionar subconjuntos de features e montar mini árvores de decisão. Forest significa floresta, já que são geradas várias árvores de decisão.

Figura 12: Modelo Random Forest



Fonte: Medium

Ou seja, basicamente, o algoritmo possui 4 passos:

Tabela 1: Passos Random Forest.

Passo	Ação
1	Seleção aleatória de algumas features;
2	Seleção da feature mais adequada para a posição de nó raiz;
3	Geração dos nós filhos;
4	Repete os passos acima até que se atinja a quantidade de árvores desejada.

Fonte: Autor

Após o modelo ser gerado, as previsões são feitas a partir de “votações”. Cada mini árvore toma uma decisão a partir dos dados apresentados. A decisão mais votada é a resposta do algoritmo.

Se olharmos atentamente, a forma de funcionamento do random forest é baseada em *Bootstrapp Aggregation (Bagging)*, o que o torna um algoritmo *ensambled*, que nada mais é do que a combinação de previsões de múltiplos algoritmos de machine learning juntos, de forma a obter previsões mais acuradas do que qualquer modelo individual.

4.5.4 Extreme Gradient Boosting (XGboost)

Modelos XGBoost constituem ensembles de árvores de regressão, formulam hipóteses sobre os exemplos agregando as respostas de uma assembleia de preditores simples. O conjunto de árvores de regressão que compõem esta assembleia é elaborado em duas etapas: (1) uma árvore T_0 é construída adicionando à sua estrutura a ramificação do atributo F_i que mais aperfeiçoa o preditor a cada etapa e, definida sua estrutura, são calculados os valores ótimos para as folhas l ; (2) a inclusão de novas árvores $T_1...N$ ao ensemble é orientada pelo erro residual do modelo, de maneira que novos preditores complementem as imperfeições dos anteriores (FRIEDMAN, 2002).

Modelos XGBoost, contudo, diferem de outras técnicas de Gradient Boosting pois empregam um algoritmo sensível à dispersão na busca por ramificações, que torna a complexidade computacional do modelo linear ao número de observações não ausentes. Assim como integram otimizações do uso de recursos que permitem calcular paralelamente a aptidão dos atributos (CHEN; GUESTRIN, 2016).


4.5.5 REDES NEURAIS ARTIFICIAIS (RNAs)

Redes Neurais Artificiais (RNAs) são sistemas de reconhecimento de padrões inspirados nos neurônios e sinapses do cérebro humano (INMAN; PEDRO; COIMBRA, 2013). São compostas por unidades simples de processamento, organizadas em arquiteturas especializadas e submetidas a um processo de treinamento. Durante este processo, ajustam a força das sinapses para minimizar o erro de suas respostas aos exemplos apresentados, aperfeiçoando sua habilidade de identificar padrões e mapear os relacionamentos entre os dados (PAOLI et al., 2010). Um neurônio artificial k , representado pela Figura 4, combina os sinais de entrada $x_1...x_m$ aos pesos sinápticos ajustados durante o treinamento $w_{k1}...w_{km}$ e um termo de bias b_k , por meio da Equação abaixo.

$$v_k = \sum_{j=1}^m w_{kj}x_j + b_k \quad (5)$$

O potencial de ativação v_k do neurônio é transferido para o domínio de uma função de ativação $\phi(\cdot)$ que pode apresentar o formato de uma curva suave, como funções.


Figura 13: Representação de um Neurônio Artificial



Fonte: Haykin (2009).

sigmóide, ou restringir os resultados a valores específicos, como funções de limiar (Threshold), apresentadas na Figura . Por fim, a resposta y_k do neurônio é transmitida à camada subsequente na arquitetura.

Figura 14: Funções de ativação Limiar (Threshold) e Sigmóide.



Fonte: Haykin (2009).

4.5.6 AVALIAÇÃO DAS PREDIÇÕES

As métricas de avaliação de modelos são ferramentas essenciais para medir o desempenho e a qualidade dos modelos de aprendizado de máquina. Essas métricas fornecem insights sobre como um modelo está se comportando em relação aos dados de treinamento e teste, permitindo que os desenvolvedores e cientistas de dados tomem decisões informadas sobre sua eficácia e eficiência. Neste texto, vamos explorar algumas das métricas de

avaliação mais comumente usadas, juntamente com suas fórmulas correspondentes.

Uma das métricas mais básicas e amplamente utilizadas é a acurácia (accuracy). Ela mede a proporção de predições corretas em relação ao total de predições feitas pelo modelo. A fórmula da acurácia é simples:

$$Acurácia = \frac{Predições\ corretas}{Total\ de\ Predições} \quad (6)$$

Embora a acurácia seja uma métrica útil, ela pode não ser adequada para todos os cenários, especialmente quando os dados estão desbalanceados, ou seja, quando há uma grande diferença entre o número de amostras em cada classe. Nesses casos, métricas como a precisão (precision) e a revocação (recall) podem fornecer informações mais relevantes.

A precisão mede a proporção de verdadeiros positivos (TP) em relação à soma de verdadeiros positivos e falsos positivos (FP). Ela é especialmente útil quando o foco está em minimizar os falsos positivos. A fórmula da precisão é dada por:

$$Precisão = \frac{TP}{TP+FP} \quad (7)$$

A revocação, por sua vez, mede a proporção de verdadeiros positivos em relação à soma de verdadeiros positivos e falsos negativos (FN). É uma métrica importante quando o objetivo é minimizar os falsos negativos. A fórmula da revocação é:

$$recall = \frac{TP}{TP+FN} \quad (8)$$

A precisão e a revocação estão relacionadas, e muitas vezes é necessário encontrar um equilíbrio entre elas. Para isso, podemos usar a métrica conhecida como F1-score, que é a média harmônica entre a precisão e a revocação. A fórmula do F1-score é:

$$F1 - score = \frac{Precisão * recall}{Precisão + recall} \quad (9)$$

Além dessas métricas, existem outras que podem ser úteis em diferentes contextos. Por exemplo, quando as classes não estão equilibradas e é necessário levar em consideração a taxa de falsos positivos e falsos negativos simultaneamente, a curva ROC (Receiver Operating Characteristic) e a área sob a curva ROC (AUC-ROC) podem ser usadas.

A curva ROC é um gráfico que mostra a taxa de verdadeiros positivos em função da taxa de falsos positivos, variando o limiar de classificação do modelo. A área sob a curva ROC (AUC-ROC) é uma métrica que resume a curva ROC em um único valor numérico, fornecendo uma medida da capacidade de discriminação do modelo. Quanto maior a AUC-ROC, melhor o desempenho do modelo. A fórmula para o cálculo da AUC-ROC é baseada na integral da curva ROC.

Existem também métricas específicas para problemas de regressão, como o erro médio absoluto (Mean Absolute Error - MAE), que mede a média das diferenças absolutas entre as previsões e os valores reais, e o erro quadrático médio (Mean Squared Error - MSE), que mede a média dos quadrados das diferenças entre as previsões e os valores reais.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (10)$$

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (11)$$

Onde y_i é o valor real, \hat{y}_i é a previsão do modelo e n é o número total de amostras.

Para problemas de regressão, além do MAE e MSE mencionados anteriormente, temos o coeficiente de determinação (R^2), que mede a proporção da variabilidade dos dados explicada pelo modelo. O R^2 varia entre 0 e 1, onde 1 indica uma correspondência perfeita entre as previsões e os valores reais, e 0

indica que o modelo não é capaz de explicar a variabilidade dos dados. A fórmula do R^2 é:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (12)$$

Onde y_i é o valor real, \hat{y}_i é a previsão do modelo e \bar{y} é a média dos valores reais.

Além das métricas individuais, é importante considerar também a validação cruzada (cross-validation) e o uso de conjuntos de treinamento, validação e teste para avaliar o desempenho geral do modelo. A validação cruzada envolve dividir os dados em diferentes conjuntos para treinamento e teste, executando o treinamento e a avaliação várias vezes para obter uma estimativa mais robusta do desempenho do modelo.

5 RESULTADOS E DISCUSSÃO

Os resultados da implementação do sistema serão avaliados quanto à eficiência energética e facilidade de uso. A pesquisa realizada para o desenvolvimento do sistema de gerenciamento de energia para edifícios inteligentes apresentou resultados positivos quanto à eficiência do sistema. Ao utilizar tecnologias de IoT e aprendizado de máquina, o sistema conseguiu detectar e prever picos de consumo de energia, e otimizar o uso dos recursos energéticos de maneira mais eficiente.

5.1 DATASET

O conjunto de dados contém arquivos diferentes com dados de hora em hora para 16 tipos de prédios comerciais e prédios residenciais. Os dados estão disponíveis para um ano meteorológico típico em locais nos Estados Unidos. O tamanho total desse conjunto de dados é de aproximadamente 4,8 GB compactado ou 19 GB não compactado. Foram coletados dados do ano de 2004 de diferentes fontes de consumo de energia, tais como aquecedor de água, eletricidade, aquecimento de gás, entre outros.

Esses dados foram criados pela primeira vez por volta de 2012 como um subproduto de várias análises de energia solar fotovoltaica e aquecimento solar de água (consulte as referências abaixo para ver dois exemplos). Este conjunto de dados contém vários erros e limitações. Recomenda-se que os usuários deste conjunto de dados façam a transição para a versão atualizada do conjunto de dados publicada nos recursos. Este conjunto de dados contém dados meteorológicos, dados de perfil de carga comercial e dados de perfil de carga residencial.

O Ano Meteorológico Típico 3 (TMY3) fornece um ano de dados horários para cerca de 1.000 locais. O clima TMY representa normais de 30 anos, que são condições climáticas típicas em um período de 30 anos.

Os perfis de carga comercial incluídos são os 16 Modelos de Protótipos Comerciais ASHRAE 90.1-2004 DOE simulados em todos os locais TMY3, com níveis de isolamento de construção alterados com base nos requisitos ASHRAE 90.1-2004 em cada zona climática. Os nomes das pastas dentro de cada recurso representam a localização da estação meteorológica dos perfis, enquanto os nomes dos arquivos representam o tipo de construção e a cidade representativa da zona climática ASHRAE que foi usada para determinar os níveis de isolamento de conformidade com o código. Conforme indicado pelos nomes dos arquivos, todos os modelos de construção representam construções em conformidade com os requisitos do código de energia de construção ASHRAE

90.1-2004. Nenhuma safra de edifícios mais antiga ou mais recente é representada.

Os perfis de carga residencial BASE são cinco modelos EnergyPlus (um por região climática) representando 2009 IECC construção de residências unifamiliares simuladas em todos os locais TMY3. Nenhuma safra de edifícios mais antiga ou mais recente é representada. Cada uma das cinco regiões climáticas inclui apenas um tipo de combustível para aquecimento; aquecimento elétrico só é encontrado no clima quente-úmido. Ar-condicionado não é encontrado na região de clima marinho.

O conjunto de dados residencial inclui um perfil de carga de construção ALTO que foi concebido para fornecer uma aproximação aproximada de casas antigas, mas combina isolamento térmico ruim com tamanho de casa maior, pontos de ajuste de termostato mais rígidos e equipamentos HVAC menos eficientes. Por outro lado, o edifício LOW combina excelente isolamento térmico com tamanho de casa menor, pontos de ajuste de termostato mais amplos e equipamentos HVAC mais eficientes. No entanto, não se sabe o quão bem essas permutações HIGH e LOW representam a faixa de uso de energia no estoque habitacional.

Para desenvolvimento deste trabalho foi separado apenas uma amostra do dataset, pois logisticamente se torna mais viável já que todo ele tem o mesmo formato.

5.1.1 OBTENÇÃO DOS DADOS

Os dados em edifícios inteligentes são obtidos por meio da Internet das Coisas (IoT). Sensores são colocados em diferentes partes do edifício, como salas, corredores, banheiros e outros espaços para coletar dados sobre o ambiente, tais como temperatura, umidade, qualidade do ar e níveis de iluminação. Os sensores utilizados podem ser de diferentes tipos e modelos, dependendo das informações que precisam ser coletadas. Por exemplo, sensores de temperatura e umidade podem ser instalados em cada sala para monitorar o clima interno, enquanto sensores de movimento podem ser

colocados em áreas comuns, como corredores e escadas, para identificar o fluxo de pessoas e otimizar o uso de iluminação e ar-condicionado.

Esses sensores podem ser conectados a uma rede sem fio, como Wi-Fi ou Bluetooth, ou a uma rede de sensores específica, como Zigbee ou LoRaWAN. As informações coletadas pelos sensores são transmitidas através da rede para um gateway, que é um dispositivo responsável por coletar e processar os dados

Com o uso de tecnologias avançadas, esses sistemas podem analisar os dados coletados em tempo real e identificar padrões e tendências que ajudam a melhorar a eficiência energética do edifício, otimizar o uso de recursos e melhorar o conforto dos ocupantes. Além disso, esses sistemas também podem ser usados para detectar anomalias e problemas, tais como vazamentos de água ou falhas nos sistemas de HVAC (aquecimento, ventilação e ar condicionado), permitindo que sejam corrigidos rapidamente.

Em resumo, os dados em edifícios inteligentes são obtidos através da instalação de sensores conectados a uma rede, que coletam informações sobre o ambiente e os enviam para um sistema central de gerenciamento de dados, que os analisa para melhorar a eficiência energética, a gestão de recursos e o conforto dos ocupantes.

5.1.2 PRÉ-PROCESSAMENTO DOS DADOS

Pré-processamento de dados e ETL (Extract, Transform, Load) são duas etapas essenciais no processo de gerenciamento de dados em um ambiente de negócios. O pré-processamento de dados refere-se ao processo de limpeza e preparação dos dados brutos para análise ou processamento adicional. Já o ETL refere-se ao processo de extração de dados de várias fontes, transformação desses dados para atender às necessidades específicas do usuário e, em seguida, carregamento desses dados em um destino desejado, como um banco de dados.

Figura 15 : Importando as bibliotecas e os dados para o Google Colab.

```
[1] #importando bibliotecas para trabalhar os dados
import pandas as pd

[2] dados = "/content/drive/MyDrive/dados tcc/USA_CA_Oakland.Intl.AP.724930_TMY3/RefBldgFullServiceRestaurantNew2004_7.1_5.0_3C_USA_CA_SAN_FRAN
data = pd.read_csv(dados)

data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 8760 entries, 0 to 8759
Data columns (total 11 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Data/Hora                             8760 non-null   object
1   Consumo                               8760 non-null   float64
2   fans                                  8760 non-null   float64
3   Resfriamento                         8760 non-null   float64
4   Aquecimento                           8760 non-null   float64
5   InteriorLuzes                         8760 non-null   float64
6   InteriorEquipamento                 8760 non-null   float64
7   Gás:Instalação                       8760 non-null   float64
8   Aquecimento:Gás                      8760 non-null   float64
9   InteriorEquipamento:Gás             8760 non-null   float64
10  Aquecedor de água:Sistemas de água   8760 non-null   float64
dtypes: float64(10), object(1)
memory usage: 752.9+ KB
```

Fonte : autor

O pré-processamento de dados inclui várias tarefas, como a remoção de duplicatas, correção de erros, preenchimento de valores ausentes e normalização dos dados para garantir a consistência. A normalização envolve a escala dos dados para que todos estejam na mesma faixa e possam ser comparados. Isso ajuda a evitar distorções ou vies nos resultados da análise de dados.

Figura 16: Transformação dos dados:

```

[4] renomear = ['Data/Hora', 'Consumo', 'fans', 'Resfriamento', 'Aquecimento', 'InteriorLuzes',
               'InteriorEquipamento', 'Gás:Instalação', 'Aquecimento:Gás', 'InteriorEquipamento:Gás', 'Aquecedor de água:Sistemas de água']
data.columns = renomear

# Substituindo caracteres da data de pedido
data_ele['Data/Hora'] = data_ele['Data/Hora'].str.replace(' ', '-')
# Separando a data de pedido em Dia, Mês e Ano.
data_ele[['Data', 'Hora']] = data_ele['Data/Hora'].str.split('-', expand=True)
data_ele[['mes', 'dia']] = data_ele['Data'].str.split('/', expand=True)
data_ele.drop('Data/Hora', inplace = True, axis=1)
data_ele.drop('Data', inplace = True, axis=1)

[7] from sklearn.preprocessing import LabelEncoder
# Codificar as variáveis categóricas
le = LabelEncoder()
data_ele["Hora"] = le.fit_transform(data_ele["Hora"])

[8] data_ele["mes"] = data_ele["mes"].astype(float)
data_ele["dia"] = data_ele["dia"].astype(float)

[10] data.drop_duplicates()

```

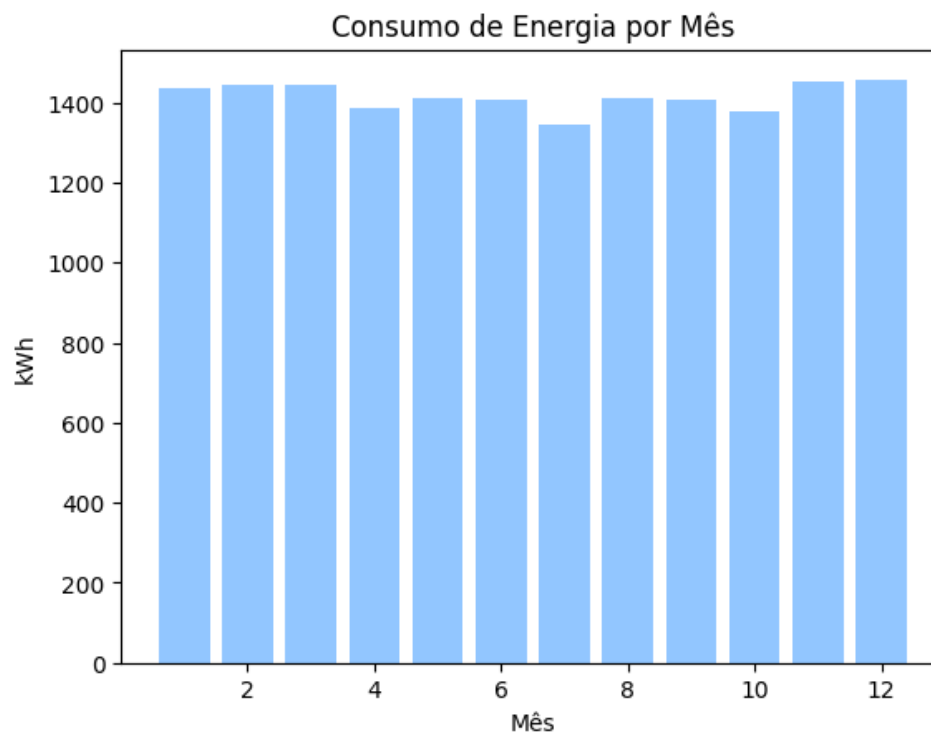
Fonte: Autor

5.1.3 VISUALIZAÇÃO DOS DADOS

A visualização de dados é uma técnica utilizada para representar informações de maneira gráfica e intuitiva. Ela permite aos usuários identificar padrões e tendências em grandes conjuntos de dados, tornando mais fácil a tomada de decisões informadas.

Ela pode ser feita de várias maneiras, incluindo gráficos de barras, gráficos de pizza, gráficos de linhas, mapas e muito mais. Cada tipo de gráfico é adequado para diferentes tipos de dados e insights que se deseja obter.

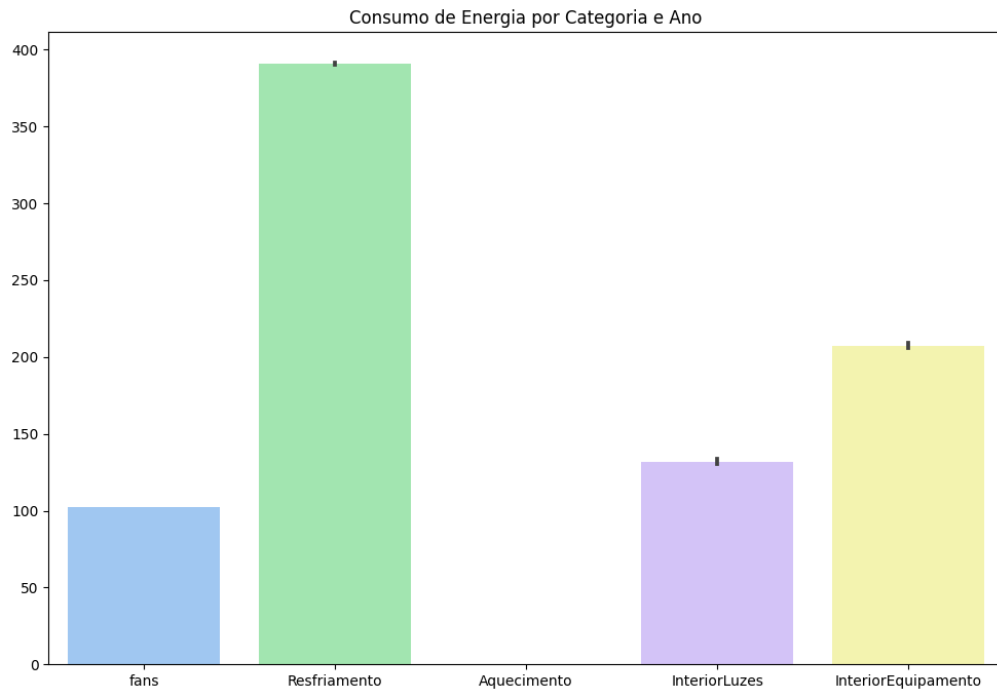
Figura 17: Consumo energético por mês.



Fonte: Autor.

A Figura 17 ilustra a distribuição do consumo mensal de energia ao longo de um ano. É evidente que essa distribuição é uniforme, com o menor consumo ocorrendo no mês 7 e o maior no mês 12. Essa observação é facilmente perceptível ao analisar o gráfico, que demonstra uma consistência nos níveis de consumo durante os meses intermediários, seguidos por um aumento gradual até atingir o pico no final do ano. Essa distribuição uniforme no consumo de energia ao longo do ano pode ter várias implicações, incluindo fatores climáticos, sazonalidade e tendências socioeconômicas.

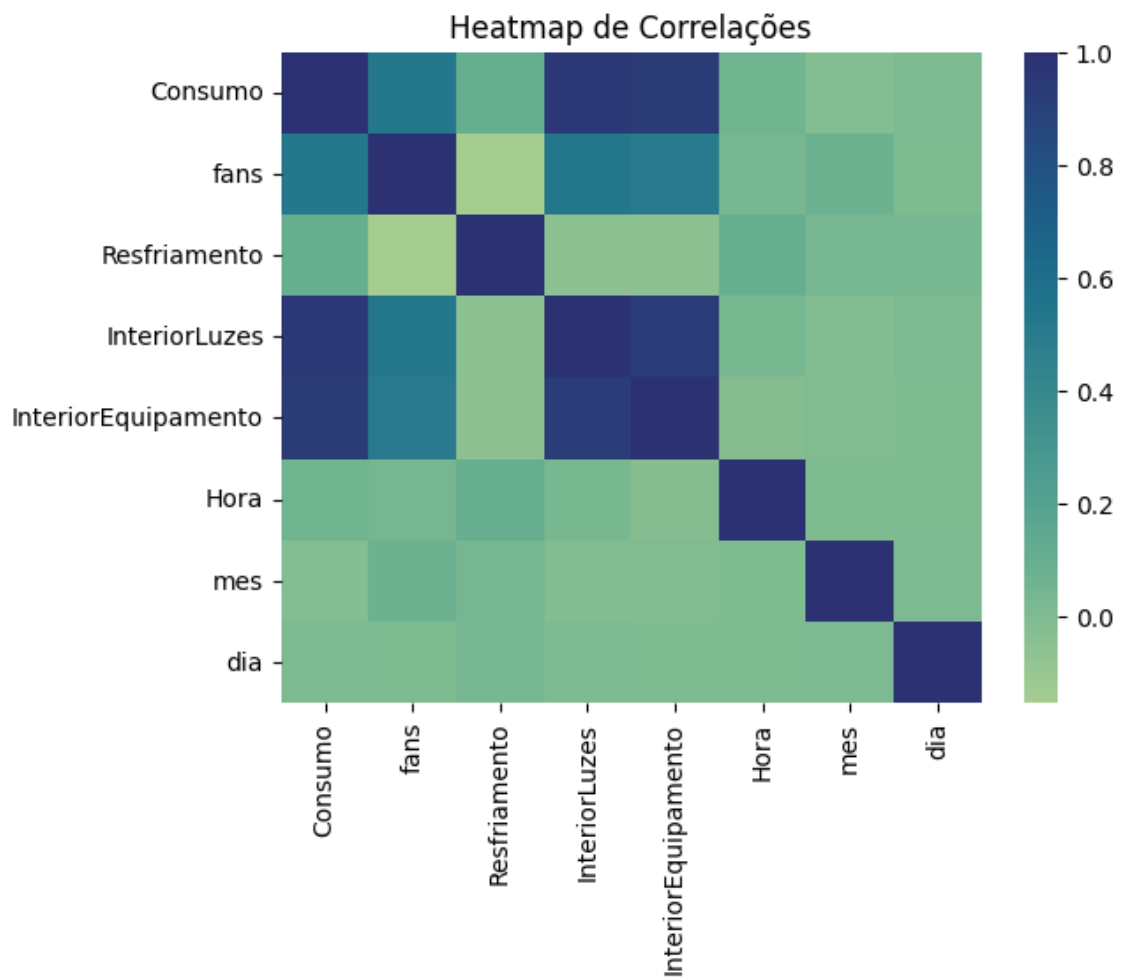
Figura 18: Consumo por Categoria em kW.



Fonte: Autor

De acordo com a figura 18, é evidente que o resfriamento é o principal responsável pelo maior gasto energético deste móvel. Essa observação pode ser atribuída à região em que se encontra e ao desejo dos proprietários por conforto. A necessidade de manter uma temperatura agradável e controlada pode exigir um consumo maior de energia para o funcionamento de sistemas de resfriamento, como ar-condicionado. Essa informação destacada na figura 18 ressalta a importância de considerar estratégias de eficiência energética e alternativas sustentáveis para minimizar o impacto ambiental e reduzir os custos associados ao resfriamento do ambiente.

Figura 19: Gráfico de correlação.



Fonte: Autor.

Foi plotado o gráfico de heatmap para verificar quais são os dados com maior correlação entre eles.


Verificamos que as colunas com maior correlação são: Interior luzes e interior equipamentos, pois são as que possuem uma maior porcentagem no consumo energético do imóvel.

5.1.4 APLICAÇÃO DOS ALGORITMOS

Foram aplicados vários algoritmos de inteligência artificial no conjunto de dados e cada um foram otimizados a partir dos melhores hiper parâmetros para cada modelo e foram avaliadas as métricas de cada um.

obtivemos os seguintes resultados para cada modelo de predição, para o algoritmo de Regressão linear, temos os seguintes resultados.

Figura 20: Regressão Linear



Fonte: Autor

O modelo consegue prever o consumo futuro tendo como base os dados, podem não acerta 100% os valores dos dados target.

A avaliação das métricas desse modelo ficou da seguinte forma:

Tabela 2: Avaliação da regressão linear


Métricas	Resultado
MSE	1879.7146788503753
MAE	34.65031121695807
MAPE	0.034081477288230654

Fonte: Autor

O modelo apresenta um erro médio quadrático relativamente alto (MSE), mas um erro médio absoluto relativamente baixo (MAE). Além disso, a precisão média do modelo em termos de porcentagem (MAPE) é de aproximadamente 96.59%. Essas métricas fornecem uma visão geral do desempenho do modelo.

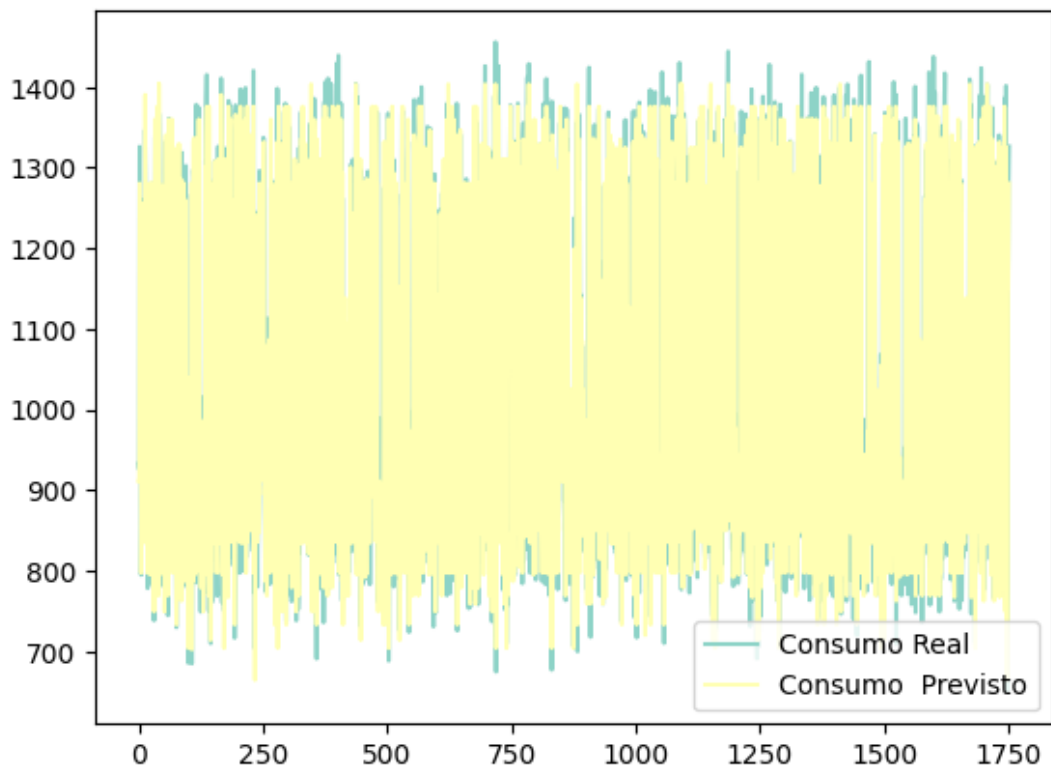
Ao aplicarmos o modelo de árvore de decisão aos mesmos dados, obtivemos uma árvore de decisão que demonstrou o seguinte comportamento: ela analisou as características do conjunto de dados e tomou decisões com base em critérios específicos em cada nó interno. Essas decisões permitiram que a árvore se ramificasse para diferentes caminhos, representando diferentes possibilidades de classificação ou previsão. Ao seguir os nós internos e chegar às folhas, a árvore forneceu as decisões finais ou previsões para cada instância de dados. Essa árvore de decisão ofereceu uma representação clara e interpretável do processo de tomada de decisão para o conjunto de dados em questão.

Figura 21: Arvore do modelo



A partir do nó raiz, a árvore de decisão estabelece conexões com várias folhas por meio de nós internos, o que permite uma previsão detalhada e precisa. Cada nó interno representa uma condição ou critério de divisão que guia o processo de tomada de decisão. Essas divisões levam a diferentes caminhos na árvore, direcionando a análise para subsets específicos dos dados. Essa estrutura hierárquica proporciona uma visão detalhada das diferentes possibilidades e cenários de previsão. Ao seguir esses caminhos, podemos obter previsões mais refinadas e compreender melhor como as características dos dados influenciam nas decisões e resultados obtidos.

Figura 22: Predição Arvore de decisão



Fonte: Autor

De maneira evidente, a árvore de decisão apresentou um desempenho de previsão superior à regressão linear. Para aprimorar essa avaliação, utilizamos métricas de avaliação específicas para a árvore de decisão. Essas métricas nos permitiram quantificar a qualidade das previsões feitas pelo

modelo, oferecendo uma análise mais precisa e objetiva do seu desempenho. Ao comparar as métricas obtidas com as da regressão linear, ficou evidente que a árvore de decisão proporcionou resultados mais acurados e confiáveis. Essa constatação ressalta a eficácia desse modelo para a tarefa em questão e reforça sua superioridade em relação à regressão linear.

Tabela 3: Avaliação da Arvore de decisão


Métricas	Resultado
MSE	840.2387549691482
MAE	22.24359589312232
MAPE	0.022413730837529327

Fonte: Autor

O modelo apresenta um erro médio quadrático relativamente baixo (MSE) e um erro médio absoluto relativamente baixo (MAE). Além disso, a precisão média do modelo em termos de porcentagem (MAPE) é de aproximadamente 97.76%. Essas métricas indicam que o modelo tem um bom ajuste aos dados e uma precisão razoavelmente alta em suas previsões.

Utilizamos, adicionalmente, o modelo de Random Forest para realizar a análise do conjunto de dados. A Random Forest é uma técnica de aprendizado de máquina que combina várias árvores de decisão para melhorar a precisão das previsões. Essa abordagem é especialmente útil para lidar com conjuntos de dados complexos, pois permite capturar relações não lineares e interações entre as variáveis. Ao aplicar a Random Forest, conseguimos obter uma representação mais abrangente do padrão de dados e alcançar resultados mais confiáveis. A eficácia dessa técnica reforça a qualidade da análise e das conclusões obtidas a partir do conjunto de dados em questão.⁴

Figura 23: Predição Random Forest



Fonte: Autor

O modelo demonstrou uma taxa de acurácia semelhante à regressão linear, porém inferior à árvore de decisão, conforme evidenciado na figura 23. A taxa de acerto representa a proporção de previsões corretas realizadas pelo modelo em relação ao total de amostras avaliadas. Nesse contexto, a figura 23 exibe as informações que comprovam essa comparação de desempenho entre os modelos. Observa-se que a árvore de decisão apresentou uma taxa de acerto superior, indicando sua capacidade de realizar previsões mais precisas e assertivas em relação ao modelo em questão e à regressão linear.

Tabela 4: Avaliação Random Forest

Métricas	Resultado
MSE	1167.8465435646535
MAE	27.165058755688396
MAPE	0.027340144497307615

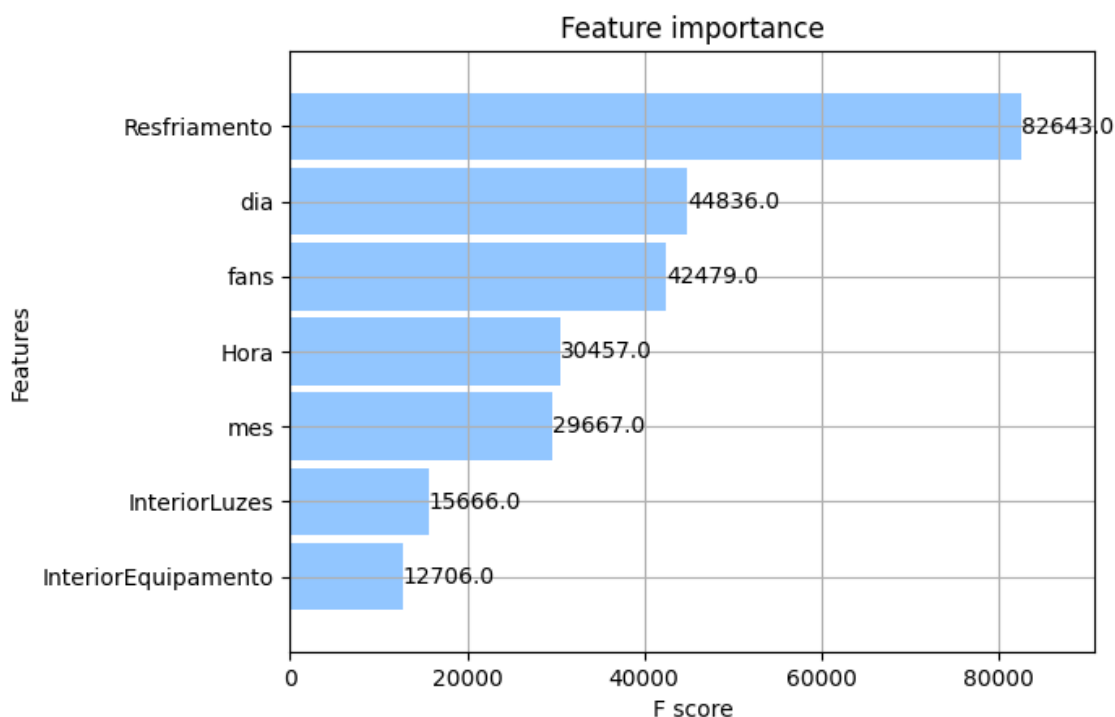
Fonte: Autor

O modelo apresenta um erro médio quadrático relativamente baixo (MSE) e um erro médio absoluto relativamente baixo (MAE). Além disso, a precisão média do modelo em termos de porcentagem (MAPE) é de aproximadamente 97.27%. Essas métricas indicam que o modelo possui um bom ajuste aos dados e uma precisão razoavelmente alta em suas previsões.

Para efeito de comparação aplicaremos ao conjunto de dados o modelo XGboost para analisar como ele prediz os dados.

A fim de estabelecer uma comparação, utilizaremos o modelo XGBoost para analisar o conjunto de dados e avaliar sua capacidade de previsão. Ele é um algoritmo de aprendizado de máquina avançado que combina várias árvores de decisão para melhorar a precisão das previsões. Ao aplicar o XGBoost ao conjunto de dados, poderemos observar como ele se comporta e como suas previsões se comparam aos resultados de outros modelos. Essa análise nos permitirá entender o desempenho e a eficácia do XGBoost na tarefa em questão, fornecendo informações valiosas para a tomada de decisões futuras.

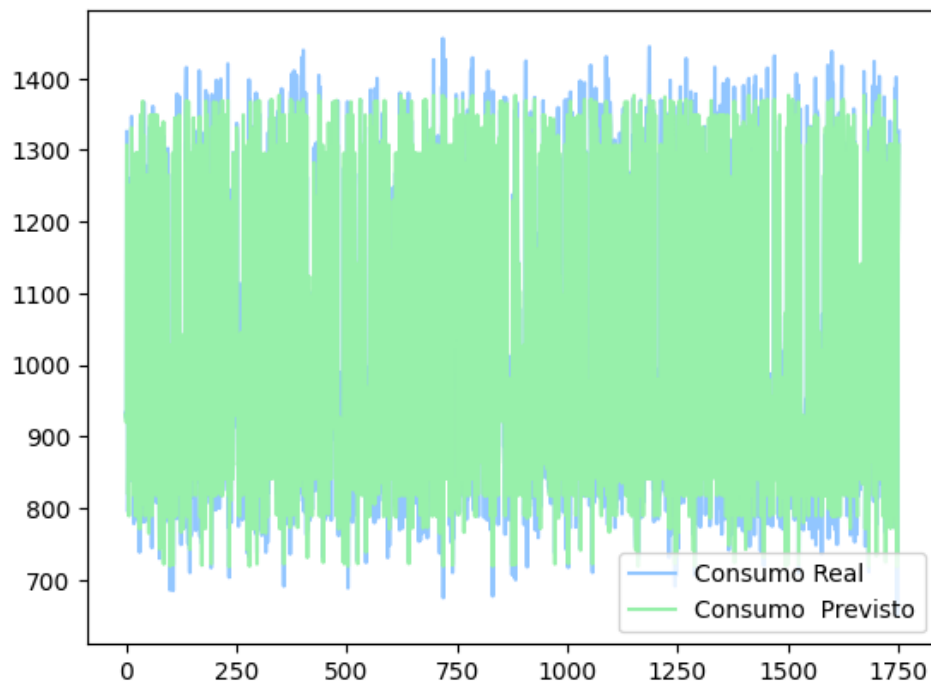
Figura 24: Features Importantes.



Fonte: Autor

De acordo com o XGBoost, a feature de maior importância para o modelo é o resfriamento. Isso indica que o resfriamento tem um impacto significativo nas previsões e influencia fortemente a capacidade do modelo de fazer estimativas precisas e assertivas.

Figura 25: Predição XGBoost



Fonte: Autor

Com base na análise do gráfico, podemos observar que o modelo obteve uma taxa de acerto significativamente alta em comparação com os outros modelos avaliados. Isso indica que o modelo foi capaz de realizar previsões precisas e confiáveis, demonstrando seu bom desempenho na tarefa em questão. A alta taxa de acerto evidencia a capacidade do modelo em capturar os padrões e tendências dos dados, resultando em uma correspondência mais próxima com os valores reais. Esses resultados destacam a eficácia do modelo em fornecer informações valiosas e confiáveis, permitindo uma tomada de decisão mais informada e embasada.

Tabela 5: Avaliação XGBoost

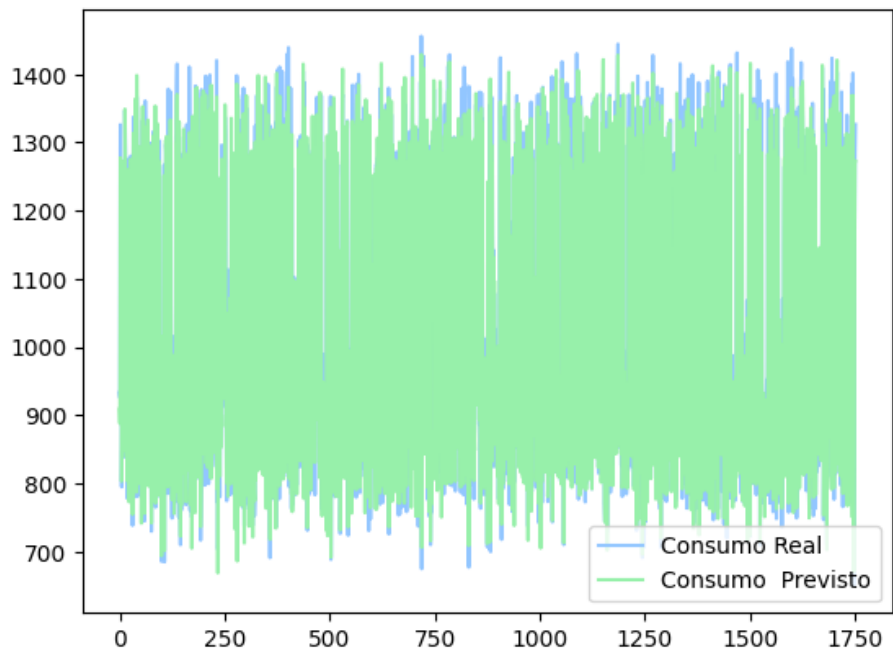
Métricas	Resultado
MSE	194.20520068541927
MAE	10.18289187739935
MAPE	0.010089154540927053
RMSE	13.935753

Fonte: Autor

o modelo apresenta um erro médio quadrático (MSE) e um erro médio absoluto (MAE) relativamente baixos, indicando um bom ajuste aos dados. Além disso, a precisão média em termos percentuais (MAPE) é de aproximadamente 98.99%. O valor do RMSE também é baixo, sugerindo que os erros entre os valores reais e os valores previstos estão próximos. Essas métricas indicam que o modelo tem um bom desempenho na previsão dos dados.

Vamos agora aplicar um último modelo, uma rede neural artificial, para analisar seu comportamento em relação ao conjunto de dados. As redes neurais artificiais são algoritmos de aprendizado de máquina inspirados no funcionamento do cérebro humano, capazes de aprender e identificar padrões complexos nos dados. Ao aplicar a rede neural ao conjunto de dados, poderemos investigar como ela se adapta, processa as informações e realiza previsões. Essa análise nos permitirá avaliar a capacidade da rede neural em lidar com a complexidade dos dados, identificar correlações e obter insights valiosos para o problema em questão.

Figura 26: Predição RNA



Fonte: Autor

Ao analisarmos os dados, observamos que o modelo de Rede Neural Artificial (RNA) apresenta um comportamento distinto em relação ao XGBoost na previsão de consumo. Os resultados indicam que a RNA possui uma abordagem única e diferente em relação ao XGBoost para lidar com os dados e fazer as previsões. Essa discrepância sugere que a RNA pode considerar diferentes aspectos e relações nos dados, resultando em resultados de previsão distintos. É importante levar em conta essa diferença de comportamento ao interpretar e comparar as previsões desses dois modelos, pois cada um pode oferecer insights valiosos e complementares para a compreensão do consumo.

Tabela 6: Avaliação RNA

Métricas	Resultado
MSE	1029.404162591009
MAE	25.440399286435415
MAPE	0.02503091884116756
Acurácia (R²)	0.98

Fonte: Autor

Em resumo, os dados indicam que o modelo apresenta um erro médio quadrático (MSE) e um erro médio absoluto (MAE) relativamente baixos, além de uma alta acurácia (R^2). Isso sugere que o modelo tem um bom ajuste aos dados e é capaz de fazer previsões com uma precisão considerável.

6 CONCLUSÃO

Os resultados da simulação do sistema, observando que o modelo que melhor atende as especificações dos dados dos edifícios é o XGBoost as análises mostraram uma redução significativa no consumo de energia em comparação a um edifício convencional, o que indica que o sistema é eficaz na otimização do uso de energia. Além disso, a análise de dados também revelou que o sistema é capaz de adaptar-se a mudanças no padrão de consumo, ajustando automaticamente sua estratégia de gerenciamento de energia.

A discussão dos resultados destaca a importância da utilização de sistemas de gerenciamento de energia avançados para a promoção da eficiência energética e a sustentabilidade. Além disso, a análise dos resultados indica que ainda há espaço para melhorias, especialmente no que diz respeito à integração de diferentes sistemas de gerenciamento de energia e à escalabilidade do sistema.

As pesquisas apontam que a utilização de sistemas de gerenciamento de energia eficientes e avançados pode ter um impacto significativo na redução do consumo de energia em edifícios. Assim, é importante continuar investindo em pesquisa e desenvolvimento nesta área, para que possamos alcançar um futuro mais sustentável.

Em conclusão, os resultados da pesquisa sugerem que o sistema desenvolvido é eficiente e capaz de melhorar a eficiência energética em edifícios inteligentes. No entanto, é importante continuar investindo em pesquisa e desenvolvimento para superarmos os desafios e barreiras existentes, a fim de promover ainda mais a eficiência energética e a sustentabilidade.

7 REFERÊNCIA

ARCHITIZER. Architizer. Architizer, 2014. Disponível em: <<http://architizer.com/blog/7-intelligent-buildings-that-prove-digitally-driven-design-works/>>.

Acesso em: 1 fev. 2023.

BISHOP, C. M. **Pattern Recoginiton and Machine Learning**. [S.l.: s.n.], 2006. ISBN 978-0-387-31073-2.

BREIMAN, L. **Random forests**. **Machine Learning**, 2001. ISSN 08856125.

Brown, S.; Karnatz, K.; Knight, R. (2016). **A comprehensive look at the intelligent building**. Consult Specif Eng. Apr;53(3):54 8.

CAMPESATO, O. **Artificial Intelligence, Machine Learning, and Deep Learning**. [S.I.]: Mercury Learning and Information, 2020. ISBN 1683924673; 9781683924678.

CHEN, J. Histogram. 2022. Available from Internet: <https://www.investopedia.com/terms/h/histogram.asp>.

CHOLLET, F. **Deep Learning with Python**. [S.I.]: Manning Publications Co, 2017. ISBN 1617294438; 9781617294433.

CTBHU. **Council on Tall Buildings and Urban Habitat**. CTBHU, 2013. Disponível em: <<http://www.ctbuh.org/TallBuildings/FeaturedTallBuildings/AlBahrTowersAbuDhabi/tabid/3845/language/en-US/Default.aspx>>. Acesso em: 12 nov. 2022

CUTLER, A.; CUTLER, D. R.; STEVENS, J. R. **Random Forests**. Boston, MA: Springer US, 2012. 157Ü175 p. ISBN 978-1-4419-9326-7. Disponível em: https://doi.org/10.1007/978-1-4419-9326-7_5.

Data openei, disponível em : <https://data.openei.org/submissions/153>. Acesso em 10 de Março de 2023.

FERRER, J. A.; GARRIDO, A. **Eficiência Energética em Edifícios**. Madrid: ONUDI Observatório e Energias Renováveis para a América Latina e Caribe, 2013.

GARCIA, S.C. **O uso de árvores de decisão na descoberta de conhecimento na área da saúde**. In: SEMANA ACADÊMICA, 2000. Rio Grande do Sul: Universidade Federal do Rio Grandedo Sul, 2000.

HAYKIN, S. **Redes neurais: princípios e prática**. [S.l.]: Bookman Editora, 2007.

Howell, S.; Rezgui, Y.; Beach, T. (2017). Integrating building and urban semantics to empower smart water solutions. *Autom Constr.* 81:434 48.

H. Chen, Y. Huang, Y. Liu, and Q. Chen, "Smart building energy management system based on the Internet of Things," *Energy and Buildings*, vol. 167, pp. 817-826, 2018.

Inzlicht, M.; Schmeichel, B. J.; Macrae, C. N. (2014). Why self-control seems (but may not be) limited. *Trends Cogn Sci.* 18(3):127 33.

IPMVP – International Performance Measurement and Verification Protocol, disponível em: <https://evo-world.org/en/products-services-mainmenu-en/protocols/ipmvp>. Acesso em: 20 Fev. 2023.

ISO 50.001 – Associação Brasileira de Normas Técnicas, 2013. Disponível no site: <https://www.abnt.org.br>, consulta em 06/02/2023.

J. Kim, H. Kim, and D. Lee, "An intelligent building energy management system based on data mining and artificial neural networks," *Energy and Buildings*, vol. 138, pp. 132-139, 2017.

Kim, J.; Kim, H.; Lee, D. (2017). An intelligent building energy management system based on data mining and artificial neural networks. *Energy and Buildings*, 138:132-139.

Kwon, O.; Lee, E.; Bahn, H. (2014). Sensor-aware elevator scheduling for smart building environments. *Build Environ.* 72:332-42.

Le, M.H.; Ploix, S. (2017). Robust anticipative energy management system: Application of a smart building platform. *Build Serv Eng Res Technol.* 38(2):226-48.

LUBKEMAN, D. L.; ZHANG, J.; GHOSH, A. K.; JONES, R. H. Field results for a distribution circuit state estimator implementation. *IEEE Transactions on Power Delivery*, Piscataway, v. 15, n. 1, p. 399-406, 2000.

MOHSENIAN-RAD, A. H.; LEON-GARCIA, A. Distributed internet based load altering attacks against smart power grids. *IEEE Transactions on Smart Grid*, Piscataway, v. 2, n. 4, p. 667-674, 2011.

MONTGOMERY, D. C. *Multivariate process monitoring and control*. 6. ed. Hoboken: John Wiley & Sons, 2009. p. 494-523.

MONTICELLI, A. *State estimation in electric power systems: a generalized approach*. London: Springer, 1999. p. 01-13, 1999.

NIYATO, D.; WANG, P.; HOSSAIN, H. Reliability analysis and redundancy design of smart grid wireless communications system for demand side management. *IEEE Wireless Communication*, Piscataway, v. 19, n. 3, p. 38-46, 2012.

NIYATO, D.; WANG P. Cooperative Transmission for Meter Data Collection in Smart Grid. *IEEE Communication Magazine*, Piscataway, v. 50, n. 4, p. 90-97, 2012.

PALENSKY, P.; DIETRICH, D. Demand side management: demand response, intelligent energy systems, and smart loads. *IEEE Transactions on Industrial Informatics*, Piscataway, v. 7, n. 3, p. 381-388, 2011.

Random Forest - Como funciona, disponível em
: <https://medium.com/cinhiabpessanha/random-forest-como-funciona-um-dos->

algoritmos-mais-populares-de-ml-cc1b8a58b3b4. Acesso em 04 de Maio de 2023.

SINOPOLI, J. Smart Buildings, a handbook for the design and operation of building. 1. ed. Austin: Spicewood Publishing, 2006. 33 p.

SINOPOLI, J. Smart Building Systems for Architects, Owners and Builders. 1. ed. Amsterdã: Elsevier, 2010. 231 p.

STOUFFER, K.; FALCO, J.; SCARFONE, K. Guide to Supervisory Control and Data Acquisition (SCADA) and Industrial Control Systems Security. special publication 800-82, National Institute of Standards and Technology - NIST, 2006. p. 164.

Tawasha, R. (2018). Intelligent Building Technology Trends for 2018. Constructive Solutions.

Wu, X.; Hu, X.; Moura, S.; Yin, X. & Pickert, V. (2016). Stochastic control of smart home energy management with plug-in electric vehicle battery energy storage and photovoltaic array. Journal of Power Sources, 333:203 – 212. ISSN 0378-7753.

S. Lee, S. Kim, and J. Lee, "A review of building energy management systems," Renewable and Sustainable Energy Reviews, vol. 81, pp. 22-41, 2017.

Weekly, K.; Jin, M.; Zou, H.; Hsu, C.; Soyza, C.; Bayen, A.; Spanos, C. (2018). Building-in-Briefcase: A Rapidly-Deployable Environmental Sensor Suite for the Smart Building. Sensors. Apr 29;18(5):1381.

Yang, L.; Huang, K.; Kong, X.; Luo, Q. & Guo, H. (2019). Size optimization of a stand-alone micro-grid integrated with flexible load and the complementary of solar and wind. Journal of Renewable and Sustainable Energy, 11(2):025502.

Zeiler, W.; Vissers, D.; Maaijen, R.; Boxem, G. (2014). -in-the-. Archit Eng Des Manag. 10(1 2):108 30.

